

T.C.
SAKARYA ÜNİVERSİTESİ
BİLGİSAYAR VE BİLİŞİM BİLİMLERİ FAKÜLTESİ

ISE 402 BİTİRME ÇALIŞMASI

**BOX-JENKINS, ÜSTEL DÜZELTME YÖNTEMİ VE
YAPAY SİNİR AĞLARIYLA DOLAR KURU
TAHMİNLERİNİN KARŞILAŞTIRILMASI**

B161200050 – Kutay UZUNÇELEBİ

B161200046 – Sena EFE

B161200038 – Furkan AŞAN

**Fakülte Anabilim Dalı : BİLİŞİM SİSTEMLERİ
MÜHENDİSLİĞİ**
Tez Danışmanı : Dr. Öğr. Üyesi TUĞRUL TAŞÇI

2019-2020 Bahar Dönemi

T.C.
SAKARYA ÜNİVERSİTESİ
BİLGİSAYAR VE BİLİŞİM BİLİMLERİ FAKÜLTESİ

**BOX-JENKINS, ÜSTEL DÜZELTME YÖNTEMİ VE
YAPAY SİNİR AĞLARIYLA DOLAR KURU
TAHMINLERİNİN KARŞILAŞTIRILMASI**

ISE 402 - BİTİRME ÇALIŞMASI

Adı SOYADI

Fakülte Anabilim Dalı : **BİLİŞİM SİSTEMLERİ
MÜHENDİSLİĞİ**

Bu tez .. / .. / ... tarihinde aşağıdaki jüri tarafından oybirliği / oyçokluğu ile kabul edilmiştir.

.....
Jüri Başkanı

.....
Üye

.....
Üye

ÖNSÖZ

Bu tez çalışmasında Türkiye Cumhuriyeti ve Dünya Ekonomisi açısından büyük bir öneme sahip olan ABD dolarının ülkemiz para birimi olan Türk Lirası karşısındaki değerinin incelenmesi yapılmıştır. Gelecekte alabileceği değerler hakkında da tahminlerde bulunulmuştur. Dolar kurunun tahmin edilmesi gelecekte ekonomik gelişmeler ve yapılacak yatırımlar hakkında bilgi sahibi olabilmemiz için bizlere yardımcı olacaktır. Bu proje geliştirilirken geçmiş yıllarda gerçekleşmiş olan dolar kurunu etkileyen olaylardan da yardım alınmıştır.

Tez çalışmamızda planlanmasında, araştırılmasında, yürütülmesinde ve oluşumunda desteklerini esirgemeyen, yönlendirme ve bilgilendirmeleriyle çalışmamızı gerçekleştirmemizde yardımları olan sayın Dr .Öğr. Üyesi TUĞRUL TAŞCI'ya sonsuz teşekkürlerimizi sunarız.

İÇİNDEKİLER

ÖNSÖZ	iii
SİMGELER VE KISALTMALAR LİSTESİ.....	vi
ŞEKİLLER LİSTESİ.....	viii
TABLolar LİSTESİ.....	xi
ÖZET	xii
BÖLÜM 1.	GİRİŞ..... 1
BÖLÜM 2.	KURAMSAL TEMELLER 3
2.1.	Zaman Serisi 3
2.1.1.	Zaman Serisi Tanımları..... 3
2.1.2.	Zaman Serisi Özellikleri..... 4
2.1.3.	Zaman Serisi Bileşenleri..... 6
2.1.4.	Zaman Serisinin Sınıflandırılması..... 9
2.1.5.	Zaman Serilerinin Analizleri..... 11
2.1.6.	Zaman Serisi Analizinde Kullanılan Bazı Temel Kavramlar 12
2.1.7.	Zaman Serileri Analizin Kullanılan Yöntemler 16
2.2.	Makine Öğrenmesi 19
2.2.1.	Makine Öğrenmesi Çeşitleri 20
2.2.2.	Makine Öğrenmesi Uygulama Alanları..... 22
2.2.3.	Makine Öğrenmesi ile Tahmin Yapma 22
2.2.4.	Makine Öğrenmesi Uygulama Süreci 23
2.2.5.	Makine Öğrenmesi Algoritmaları 25
BÖLÜM 3.	ÖNERİLEN ÇÖZÜM MODELİ..... 29
3.1.	Box-Jenkins Tahmin Yöntemi..... 29
3.1.1.	Doğrusal Durağan Stokastik Modeller 31
3.1.2.	Doğrusal Durağan Olmayan Stokastik Modeller (ARIMA). 33
3.1.3.	Box-Jenkins Tahmin Yönteminin Üstün Ve Zayıf Yönleri... 33
3.2.	Üstel Düzgünleştirme Yöntemi..... 34
3.2.1.	Basit Üstel Düzgünleştirme Yöntemi 34
3.2.2.	Holt'un İki Parametrelili Doğrusal Üstel Düzgünleştirme Yöntemi (Holt Trend Metot) 36

3.2.3.	Üstel Düzeltme Yöntemin Avantajları ve Dezavantajları.....	38
3.3.	Yinelenen Sinir Ağları(Rnn).....	38
3.3.1.	Rnn Avantaj ve Dezavantajları.....	40
3.3.2.	Gradyan Kaybolma Sorunu	40
3.3.3.	Lstm.....	40
3.3.4.	Gru.....	41
BÖLÜM 4.	BULGULAR VE DEĞERLENDİRME	43
4.1.	Box-Jenkins Tahmin Yöntemi.....	44
4.2.	Üstel Düzgünleştirme Tahmin Yöntemi	53
4.3.	Lstm.....	65
BÖLÜM 5.	SONUÇ.....	68
BÖLÜM 6.	Kaynakça	69

SİMGELER VE KISALTMALAR LİSTESİ

ABD	:Amerika Birleşik Devletleri
ACF	:Otokorelasyon Fonksiyonu
ADF	:Genişletilmiş Dickey Fuller
AIC	:Akaike Bilgi Kriteri
ANN	:Yapay Sinir Ağı
AR	:Oto regresif Süreç (Auto Regressive)
ARIMA	:Durağan Olmayan Doğrusal Stokastik Modeller
ARMA	:Oto regresif Hareketli Ortalam Süreci
C	:Konjonktür Dalgalanmalar
CART	:Sınıflandırma ve Regresyon Ağacı (Classification and Regression Tree)
CNN	:Evrşimsel Sinir Ağı (Convolutional Neural Network)
DF	:Dickey Fuller
DW	:Durbin Watson Katsayısı
I	:Düzensiz Bileşenler
ID3	:Karar Ağaçları Algoritması (Decision Tree)
EUR:	:Euro
GRU	:Geçitli Tekrarlayan Birim (Gated Recurrent Unit)
KNN	:K-En Yakın Komşu Algoritması
LSTM	:Uzun Kısa Vadeli Hafıza Ağları (Long Short Term Memory)
MA	:Hareketli Oto regresif Süreç(Moving Average)
MAD	:Medyan Mutlak Sapma (Median Absolute Deviation)
MAE	:Ortalama Mutlak Hata (Mean Absolute Error)
MAPE	:Ortalama Mutlak Hata Yüzdesi (Mean Absolute Percentage Error)
MASE	:Ortalama Mutlak Ölçekli Hata (Mean Absolute Scaled Error)
ME	:Ortalama Hata (Mean Error)
MPE	:Ortalama Yüzde Hata(Mean Percentage Error)
MSE	:Hata Kareler Ortalaması(Mean Squared Error)
MSLE	:Logaritmik Hata Kareler Ortalaması(Mean Squared

	Logarithmic Error)
PACF	:Kısmi Otokorelasyon Fonksiyonu
PP	:Phillips-Perron
R^2	:Determinasyon Katsayısı
RMSE	:Hata Kareleri Ortalamasının Kökü(Root Mean Square Deviation)
RNN	:Yinelenen Sinir Ağı(Recurrent Neural Network)
S	:Mevsimsel Bileşenler
SIC	:Schwarz Bilgi Kriteri
T	:Trend
TCMB	:Türkiye Cumhuriyeti Merkez Bankası
USD	:Amerikan Doları
YSA	:Yapay Sinir Ağları
μ	:Seri Seviyesi (Ortalama)
Φ	:AR Süreç Parametresi
θ	:MA Süreç Parametresi
p	:AR Sürecinin Derecesi
d	:Fark Derecesi
q	:MA Sürecinin Derecesi
δ	:Süreç Ortalamasının Sabit Terimi
Y_t	:Gözlem Değeri
$\Phi_i(i:1, 2,..,p)$:AR Parametre Kestirimi
$\theta_i(i:1, 2,..,q)$:MA Parametre Kestirimi
wt	:ARIMA Farkı Alınmış Seri
$I(d)$:Fark Alma Derecesi
H_0	:Durağan Seri
H_1	:Durağanlığı Reddeden Seri
et	:Hata Terimi
α	:Düzenleme Katsayısı
Σ	:Toplam
γ	:Trend Düzenleme Katsayısı
π	:Yavaşlatma Katsayısı
F_t	:Üstel Düzenleme Denklemi
n	:Gözlem Sayısı

ŞEKİLLER LİSTESİ

Şekil 2.1. Trend Gösterimi (Tüzen, 2012, s. 8).....	7
Şekil 2.2. Mevsimsel Dalgalanma Gösterimi (Tüzen, 2012, s. 9)	7
Şekil 2.3. Konjonktürel Dalgalanma Gösterimi (Tüzen, 2012, s. 12).....	8
Şekil 2.4. White Noise (Kaya, 2019, s. 15)	9
Şekil 2.5. Random Walk Süreci (Kaya, 2019, s. 16).....	10
Şekil 3.6. Model Kurma Süçlerinin Basamakları (Bozdağ, 2011, s. 25)	30
Şekil 3.7. Sinir Ağlarının Kategorilere Ayrılması (Sinir Ağları, 2017)	39
Şekil 3.8. RNN ve Diğer İleri Beslemeli Ağlar (Recurrent Neural Networks And Lstm, 2018)	39
Şekil 3.9. İlk LSTM Mimarisi (Recurrent Neural Networks - 02 Long Short-Term Memory, 2017)	41
Şekil 3.10. GRU Mimari Yapısı (Simple RNN vs GRU vs LSTM, 2018)	42
Şekil 4.11. 2005-2020 Yılları Arasında Haftalık Türkiye Cumhuriyet Merkez Bankası Dolar Kurları Verilerinin Zamana Göre Değişimi Grafiği.....	44
Şekil 4.12. Türkiye Cumhuriyeti Merkez Bankası Dolar Kuru Verilerinin Koreloglamı.....	45
Şekil 4.13. Dolar Kuru Verilerinin Sabit Terimli ADF Birim Kök Test Sonucu	45
Şekil 4.14. Dolar Kuru Verilerinin Sabit Terimli ve Trendli ADF Birim Kök Testi Sonucu	46
Şekil 4.15. Dolar Kuru Verilerinin Sabit Terimsiz ADF Birim Kök Test Sonucu	46
Şekil 4.16. Logaritması Alınmış Dolar Kuru Verilerinin Zamana Göre Dağılımı	47
Şekil 4.17. Logaritması Alınmış Dolar Kuru Verilerinin Koreloglamı	47
Şekil 4.18. Logaritması Alınmış Dolar Kuru Verilerinin Sabit Terimli ADF Birim Kök Testi Sonucu	48
Şekil 4.19. Logaritması Alınmış Dolar Kuru Verilerinin Sabit Terimli ve Trendli ADF Birim Kök Testi Sonucu.....	48
Şekil 4.20. Logaritması Alınmış Dolar Kuru Verilerinin Sabit Terimsiz ADF Birim Kök Test Sonucu	48

Şekil 4.21. Logaritması ve Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Zamana Göre Dağılımı	49
Şekil 4.22. Logaritması ve Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Korelogramı	49
Şekil 4.23. Logaritması ve Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Sabit Terimli ADF Birim Kök Test Sonucu	50
Şekil 4.24. Logaritması ve Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerin Sabit Terimli ve Trendli ADF Birim Kök Test Sonucu	50
Şekil 4.25. Logaritması ve Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Sabit Terimsiz ADF Birim Kök Testi Sonucu	50
Şekil 4.26. Dolar Kuru Veri Serisinin ARIMA Modelinin Parametre Tahmin Sonucu	51
Şekil 4.27. Dolar Kuru Zaman Veri Serisinin ARIMA Modelinin 15 Haftalık Tahmin Grafiği	51
Şekil 4.28. Dolar Kuru Verilerinin Haftalık Verilerin Yıllara Göre Grafiği	53
Şekil 4.29. Dolar Kuru Verilerinin ACF ve PACF Değerleri	54
Şekil 4.30. Dolar Kuru Verilerinin Sabit Terimli ve Trendsiz PP Testi Sonuçları	55
Şekil 4.31. Dolar Kuru Verilerinin Sabit Terimli ve Trendli PP Testi Sonuçları	55
Şekil 4.32. Dolar Kuru Verilerinin Sabit Terimsiz ve Trendsiz PP Testi Sonuçları	56
Şekil 4.33. Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Sabit Terimli ve Trendsiz PP Testi Sonuçları	56
Şekil 4.34. Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Sabit Terimli ve Trendli PP Testi Sonuçları	57
Şekil 4.35. Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Sabit Terimsiz ve Trendsiz PP Testi Sonuçları	57
Şekil 4.36. Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Yıllara Göre Grafiği	58
Şekil 4.37. Birinci Dereceden Farkı Alınmış Train Veri Setinin Yıllara Göre Grafiği	59
Şekil 4.38. Basit Üstel Düzeltme Yöntemi Training ve Test Veri Setlerinin α Değeri ve RMSE Grafiği	60
Şekil 4.39. Holt Trend Metoduyla Training ve Test Veri Setlerinin β Değeri ve RMSE Grafiği	62

Şekil 4.40. Holt Trend Metoduyla Training ve Test Veri Setlerinin Otomatik Oluşturulan $\beta=0,375$ Değerinin 15 Haftalık Tahmin Grafiği	63
Şekil 4.41. Holt Yavaşlayan(Damped) Trend Metoduyla Training ve Test Veri Setlerinin $\pi=0,9$ Değeri ile 15 Haftalık Tahmin.....	64
Şekil 4.42. Holt Yavaşlayan(Damped) Trend Metoduyla Training ve Test Veri Setlerinin $\pi=0,9$ Değeri ile 15 Haftalık Tahmin Grafiği.....	64
Şekil 4.43. Dolar Kuru Verilerinin LSTM ile 15 Epoch'un Sonuçlarının Grafiği	66
Şekil 4.44. Dolar Kuru Verilerinin LSTM ile 30 Epoch Sonuçlarının Grafiği.....	67
Şekil 5.45. TCMB 2005-2020 Yılları Arasındaki Dolar Kuru Verileri Üzerinden Yapılan Tahmin Sonuçlarının Karşılaştırılması	68

TABLolar LİSTESİ

Tablo 3.1. Otokorelasyon(ACF) ve Kısmi otokorelasyon(PACF)’nun Teorik Davranışları (Akıncı, 2008, s. 41)	31
Tablo 4.2. 2005-2020 Yılları Arasındaki Haftalık Türkiye Cumhuriyet Merkez Bankası Dolar Kurları Verileri (TCMB, 2020)	43
Tablo 4.3. Dolar Kuru Zaman Veri Serisinin Gerçek ve 15 Haftalık Tahmin Değerleri	52
Tablo 4.4. Dolar Kurunun 15 Haftalık Tahmini İçin Kurulan Box-Jenkins ARIMA(1,1,2) Modelinin Hata Değerleri	53
Tablo 4.5. Basit Üstel Düzeltme Yöntemi Training ve Test Veri Setlerinin $\alpha=0,2$ için Hata Değerleri	59
Tablo 4.6. Basit Üstel Düzeltme Yöntemi Training ve Test Veri Setlerinin $\alpha=0,46$ için Hata Değerleri.....	60
Tablo 4.7. Basit Üstel Düzeltme Yöntemin $\alpha=0,46$ Değeriyle Yapılan Tahmin Değerleri	61
Tablo 4.8. Holt Trend Metoduyla Training ve Test Veri Setlerinin Otomatik Oluşturulan Beta Değerinin 15 Haftalık Tahmin İçin Hata Değerleri.....	61
Tablo 4.9. Holt Trend Metoduyla Training ve Test Veri Setlerinin Otomatik Oluşturulan $\beta=0,375$ Değerinin 15 Haftalık Tahmin İçin Hata Değerleri	62
Tablo 4.10. Holt Trend Metoduyla Training ve Test Veri Setlerinin Otomatik Oluşturulan $\beta=0,375$ Değerinin 15 Haftalık Tahmin	63
Tablo 4.11. Dolar Kuru Verilerinin LSTM ile 15 Epoch Sonuçları	65
Tablo 4.12. Dolar Kuru Verilerinin LSTM ile 30 Epoch Sonuçları	66
Tablo 4.13. Dolar Kuru Verilerinin LSTM ile 45 Epoch Sonuçları	67

ÖZET

Anahtar kelimeler: Tahmin, Box-Jenkins, Üstel Düzeltme, Yapay Sinir Ağları, Dolar, Zaman Serisi, Makine Öğrenmesi

Araştırmada 1950 yılından 2020 yılına kadar olan dolar kuru verilerini TCMB’de var olan veri tabanından alınarak ileriye yönelik bir tahminleme yapılmıştır. 2005 yılında Yeni Türk Lirasına geçilmesiyle beraber para biriminde oluşan değişikliklerinden dolayı sağlıklı tahmin yapabilmek için dolar kuru verilerinin parçalar halinde kullanılması sağlanmıştır. Bu parçalara ayrılan dolar kuru verilerinden yapay sinir ağları, üstel düzeltme yöntemi ve Box-Jenkins yöntemleriyle tahminleme gerçekleştirilmiştir. Makine öğrenmesi yapay sinir ağları algoritması kullanılarak Phyton dilinde geliştirme yapılmıştır. Box-Jenkins yöntemlerinden ARIMA modelini kullanarak Phyton dilinde geliştirilmiş ve Eviews programı ile yorumlanmıştır. Üstel düzeltme yöntemlerinden basit üstel düzeltme ve holt trend metoduyla R dilinde geliştirilmiştir. Bu tahminlerin sonuçları ve karşılaştırılmaları araştırmada gösterilmiştir. Kullanılmış olan bütün yöntemlerden elde edilen tahminler tek bir grafik üzerinde gösterilmiş ve hangi yöntemin daha sağlıklı sonuçlar verdiğinin yorumlaması yapılmıştır.

ABSTRACT

Key words: Esimation, Box-Jenkins, Exponential Smoothing, Artificial Neural Nets, Dollar, Time Series, Machine Learning

In thesis, forward estimation has been based on database of Central Bank of the Republic of Turkey (CBRT) contains the exchange rate of dollar data from 1950 to 2020. For the sake of reliable estimation the exchange rate of dollar data has been used in parts to avert the change in Turkish Lira currency in consequence of the amendment in Turkish Lira effective in 01.01.2005. These dissected exchange rate of dollar data parts’ estimation used with artificial neural nets, exponential smoothing, box-jenkins methods. Development in Phyton language has been made with machine learning artificial neural nets algorithm method. Estimation has been interpreted with E-view program use Box-Jenkins ARIMA model developed by Phyton language. Improvement has been made in R language with simple exponential smoothing and holt trend method one of the exponential smoothing method. The outcomes and comparisons of this estimation has been showed in thesis. Single graphic shows the results of estimation used all methods and results have been interpreted about which method provide more reliable outcome.

BÖLÜM 1. GİRİŞ

Tahmin, çeşitli meslek dallarında veya alanlarında gelecek için planlamalarda ve karar vermede her zaman önemli olmuştur. Tahminler nicel ve nitel olmak üzere iki türlü de yapılabilmektedir. Nitel tahmin, kişilerin tecrübeleri ve deneyimlerine dayanarak öngörülerine bakarak yapılırken; nicel tahmin ise eldeki ölçülmüş ve gerçekleşmiş olan değerler üzerinden sistematik yöntem(ler)den yararlanılarak öngörülme gerçekleştirilir. Tahminler genel olarak şirketlerin, kuruluşların veya işletmelerin ekonomik anlamda ileriye yönelik karar vermesinde, planlamalarının gerçekleşmesinde önemli rol oynamıştır ve dikkatleri üzerine çekmiştir.

Ekonomi her alanda önem bir yere sahip olan kavramdır. Bununla beraber ülkelerin refah seviyesini belirler; kurum ve kuruluşların, şirketlerin devamlılığının sağlanmasında önemli bir etkidir. İyi bir ekonomiye sahip olmak aynı zamanda zararı minimuma indirip karı maksimumda tutmaktır. Bu ifadeye bağlı kalarak, ileriye yönelik tahminlerde bulunmak ekonomistlerin gelecek için sağlıklı karar vermelerini sağlar. Ekonomistlerin ileriye yönelik tahminleri etkileyen en önemli faktörlerden biri de para birimleridir. Tüm dünya için neredeyse ortak olarak kullanılan para birimleri EURO ve USD'dir. Bu para birimlerinin gelecek ile ilgili tahminlerinde bulunmak her zaman cazip bir hal almıştır.

Projenin amacı ise yukarıda belirtilmiş ifadelere bağlı kalarak, ABD para birimi olan dolar kuru tahmini için kullanılan analiz yöntemlerinden elde edilen sonuçlara göre ortaya çıkan hata değerleri üzerinden karşılaştırma yapılarak en iyi değeri veren yöntemin belirlenmesidir. En iyi yöntemi belirlerken, veri seti olarak kullanılan dolar kuru verilerinin zamana bağlı, birbirleriyle ilişkili olmalarından dolayı zaman serileri tahmin yöntemlerinden Box-Jenkins ve Üstel Düzeltme'den yararlanılmıştır. Bunlara ek olarak, makine öğrenmesinden Yapay Sinir Ağları yöntemi, birbirleriyle karşılaştırılması için kullanılmıştır.

Bu proje beş bölümden oluşmaktadır. Birinci bölüm olarak araştırmanın her bölümlerden bahsedilerek genel bir giriş yapılmıştır. İkinci bölümde; zaman serilerinin tanımları, özellikleri, analiz yöntemleri ve içinde barındırmış olduğu bazı unsurlar da ele alınmıştır. Zaman serilerinin dışında makine öğrenmesi çeşitleri, tahmin yöntemleri ve algoritmalarından temel düzeyde bahsedilmiştir.

Üçüncü bölümde, zaman serisi tahmin yöntemlerinden Box-Jenkins ve Üstel Düzeltme yöntemi olarak iki farklı konu ele alınmıştır. Zaman serilerinde kullanılan Box-Jenkins ve Üstel Düzeltme yöntemlerinin, modellerinin ne olduğu, hangi parametreleri bulundurduğu, hangi özellikleri ve kullanılan yöntemlerin avantajları, dezavantajları detaylı bir şekilde ele alınmıştır. Yapay sinir ağların da ise RNN, LSTM, GRU, CNN yöntemlerinin özelliklerinden ve RNN yönteminin avantajları ve dezavantajlarından bahsedilmiştir.

Dördüncü bölümde ise tahmin için oluşturmak istenen Box-Jenkins ARIMA modelleri, Üstel Düzeltme modelleri ve Yapay Sinir Ağlarından LSTM modelinin uygulama esnasında gerçekleştirilen olayların en başından tahmin-sonuç bulguların sunulmasına kadar olan bütün sonuçlar sırasıyla paylaşılmıştır.

Beşinci ve son bölümde ise kullanılan tüm modellerin sonuçları tek bir grafikte gösterilerek hata değerleri ve tahmin değerleri üzerinden karşılaştırılması yapılarak en iyi sonucu veren yöntem belirlenmiştir.

BÖLÜM 2. KURAMSAL TEMELLER

2.1. Zaman Serisi

Bu bölümde mühendislik, bilim ve ticaretin pek çok dallarında uygulamaları gerçekleştirilen zaman serilerine ait konular ilerleyen bölümlerde detaylı bir şekilde anlatılması planlanmıştır.

2.1.1. Zaman Serisi Tanımları

Zaman faaliyetlerine göre zaman serisi bağımlı sürekli ve bağımsız kesikli olarak tanımlanabileceği gibi zaman faktörüne bağımlı olmadığı durumlarda zaman serisine düzenli, zaman faktörüne bağımlı olduğu durumlarda ise zaman serisine düzensiz zaman serileri olarak tanımlanır (Almahmud, 2019, s. 10).

Her bir verisi belli bir zaman farkına göre bağlantılı peş peşe ve sayısal verilerden oluşan seriye zaman serisi denilmektedir (Kaya, 2019, s. 4).

Dikkatli ve planlı bir şekilde ele alınan incelenen veriler ya da bilgiler, bir değişkenin zaman faktörünün dahil olduğu süreçte farklılıkları tanımlıyor ise ele alınan verilere zaman serileri olarak tanımlanırlar (Çevik, 1999, s. 15).

Seri, istatistiksel verilerin küme şeklinde ve bir kaideye göre dizilmesi olarak açıklanmaktadır. Zaman serisi ise zaman etkeninin seriye dahil olmasıyla meydana gelen seriler olarak ifade edilmektedir (Kaya, 2019, s. 4).

Senelik, aylık, haftalık ya da günlük verilerin zaman faktörünün içinde bulunmasıyla kayıtlı hale getirilen ve birbirlerini takip eden veri kümeleri olarak belirtilmiştir. Bu ifadeye ek olarak, aralıklı ve aralıksız sürekli olmak üzere zaman serileri iki çeşit dizin ifadesine bölünmüştür (Almahmud, 2019, s. 11).

Sınırları önceden belirlenmiş, peş peşe sıralanmış ve bir arada olan verilerden meydana gelen serilere zaman serileri denilmektedir (Kaya, 2019, s. 4).

Gözlemlemek için toplanılan verilerin geçmişte gösterilmiş olduğu hareketlerini analiz etmek ve bu sonuçlardan yola çıkarak geleceğe yönelik hareketlerini incelemek amaçlı ele alınan yöntem zaman serileri yöntemi olarak ifade edilmektedir (Olcan, 2015, s. 23).

Ele alınan verilerin ya da gözlemlerin zaman süreçlerinin(yıl, ay, hafta, gün) dahili ile birlikte gözlem değerlerinin hareket dağılımını açıklayan serilere zaman serileri olarak tanımlanmaktadır (Kaya, 2019, s. 6).

Ele alınan veriler, zaman serisi yöntemlerinde karşılıklı olarak bir diğerini takip eden ve zaman süreçlerinin sistemli aralıklarına bölünerek ölçümlendiklerine göre tanımlanırlar. Veriler yıl içinde bir defa ölçülürse yıllık, iki defa ölçülürse altı aylık, dört defa ölçülürse mevsimlik on iki defa ölçülürse aylık ve her gün ölçülür ise günlük zaman serileri olarak bahsedilmektedir (Şenyüz, 2019, s. 16).

Zaman serisi, zaman süreçlerinin sistemli aralıklara bölünmüş ve ölçümlerden oluşan bir seridir (Kaya, 2019, s. 6).

Zaman faktörüne tabi tutulan ve planlı bir şekilde ele alınan verilerden meydana gelen kümeye, zaman serileri olarak belirtilmektedir (Horosan, 2011, s. 58).

2.1.2. Zaman Serisi Özellikleri

Birçok meslek gruplarında zaman serileri adı altında gözlem verileri olarak kullanılmaktadır. Türkiye’de günlük olarak ekonomide gerçekleşen enflasyon, döviz oranlarının yükselişi veya alçalışı, ülkelerin günlük nüfusa yönelik sağlık alanındaki yaşanan ölümler gibi birçok veri hayatımızda rastlayabileceğimiz örnek olaylar zaman faktörü ile ilişkili verilerin gözlemlemesiyle meydana gelmektedir. Örneklerde de açıklandığı gibi zaman faktörüne bağlantılı ve belirli bir zaman

kesitinde peş peşe sıralanan verilerin gözlemlemesi ile veri setinin zaman serisi olduğunu göstermektedir (Güneş, 2010, s. 5).

Bu bölümde bir önceki bölümde açıklandığı gibi zaman serileri ile ilgili pek çok tanım ortaya konmuştur. Bu tanımlardan yola çıkarak dört bileşenlerden oluşma, olasılıklı(stokastik) süreç olma, bağımlılık gibi zaman serisine ait bazı özellikler vardır (Kırçıl, 2013, s. 12, s. 14).

Ele alınan zaman serisinde zaman, mevsimsel dalgalanmalar, düzensiz hareketler, trend ve konjonktürel dalgalanmalar gibi etkenleri bünyesinde barındırabilir. Ölçümlenmek istenen dizinlerden, etkenlerin içerisinde bulunan zaman faktörü haricinde diğer faktörlerin etkisi ortadan kaldırılmalıdır. Zaman serilerinde etkenlerin kaldırılması zaman serisi analizlerinin gerçekleştirilebilmesi için uygun hale getirildiği anlamı taşımaktadır (Güneş, 2010, s. 5, s. 6).

Zaman serilerinde verilerin geçmiş periyotlarda almış olduğu değerler zaman serileri olasılıklı (stokastik) olduğundan verilerinin gelecek periyotlarda bazı bakımlardan bir değer tahmin yapabilmesine olanak sağlar. Bazen zaman serilerinde veriler rastgele değerler alabilir bu gibi durumlarda zaman serisi ileriye yönelik bir tahminde bulunması pek olası olmaz. Fakat gelecek periyotlarda ait değerler geçmiş periyotlara ait değerler bilgisiyle şartlandırıldığından stokastik dağılışı içinde barındırmaktadır (Kaya, 2019, s. 7).

Deterministik olarak tanımlanan zaman serilerinde bir kesin bir şekilde ileriye yönelik bir tahmin yapılmaktadır. Ölçümlerle bir sonuca varılan verilerde olasılık kaidelerinin çerçevesinde bir sonuca varılması zaman serilerinin gerçek amacıdır. Stokastik (olasılıklı) zaman serileri ise olasılık kaidelerinin çerçevesinde bir sonuca varan serilerdir (Güneş, 2010, s. 6).

Zaman serilerinde veri setinde geçmiş periyotlara ait bilgilerden gelecek periyotlara ileriye yönelik bir tahminde bulunabiliyor olması zaman serilerinde ölçümlenen verilerin karşılıklı olarak ilişkili ve bağımlı olmasından kaynaklıdır. Kısacası zaman

serilerinin başka bir niteliği, ölçüm değerlerinin bağımlı niteliğe sahip olmasıdır. Bağımlı nitelik iç bağımlılık olarak da nitelendirilebilir (Kırçıl, 2013, s. 14).


Zaman serisinde bulunan veriler genellikle bağımlıdır ve zaman bakımından uzak olan ölçümler yakın olan ölçümlere göre daha az benzerlik oranına sahiptirler. Yani verilerin birbirleriyle olan bağlantıları zaman faktörüyle doğru orantılı değildir. Zaman serisinin iç bağımlılık özellik göstermesi ölçümlerin bağımlı yani korelasyonlu olduğu anlamına gelmektedir ve zaman serisini diğer serilerden farklılaştıran bir niteliktir. Zaman serisi analizleri ise bağımlılığın çözümlenmesine yönelik yöntemleri içinde barındırır (Kaya, 2019, s. 7).

2.1.3. Zaman Serisi Bileşenleri

Mevsimsel bileşen, konjonktürel dalgalanmalar, trend ve düzensiz bileşen zaman serisini etkileyen etkenlerdendir. Düzensiz bileşeni önceden tahmin edemezken mevsimsel bileşen, trend, konjonktürel dalgalanmalar bilirli kılınabilirler. Zaman serisi bileşenleri ise bunlardır (Çiğdem, 2009, s. 6):

- Trend(T)
- Mevsimsel Dalgalanmalar(S)
- Konjonktürel Dalgalanmalar(C)
- Düzensiz Bileşen(I)

Trend: zaman serisinin ortalamasındaki değişimler trend olarak tanımlanabilir. Trend, uzun dönemde gerçekleşen artışı ya da azalış eğilimini temsil eder. Ele alınan veri setinin uzun dönemli olduğundan, zaman serisinin mevsimlik, haftalık ya da aylık olması bir şey değiştirmez. Buna bağlı olarak, farklı dönemlerde ele alınan zaman serisinin ortalamaları da farklılık gösterecektir (Horosan, 2011, s. 63).



Şekil 2.1. Trend Gösterimi (Tüzen, 2012, s. 8)

Mevsimsel bileşen: ele alınan zaman serisinde birbirine bağlı yılların aynı haftası veya ayında eş ya da benzer gerçekleşen mevsimsel dalgalanmalar olarak tanımlanabilir. Mevsimsellik, konjontürel dalgalanmaların benzer özelliklerine sahip, yıl içinde tekrar edebilen bir yıldan uzun sürmeyen ve fazla hacimleri de bulunmayan bir bileşendir. Zaman serisinde bulunan yıllık veriler kısa dönemli verilerin toplamını ya da ortalamalarını temsil ettiğinden mevsimsel bileşen, yıllık belirlenen verilerde gözlenmemekte daha çok aylık, haftalık, günlük olan serilerde gözlenmektedir (Horosan, 2011, s. 66).



Şekil 2.2. Mevsimsel Dalgalanma Gösterimi (Tüzen, 2012, s. 9)

Konjonktürel dalgalanmalar: ekonomide oluşan refah ve durağanlık zamanlarında gerçekleşen dalgalanmalar olarak ifade edilir. Konjonktürel dalgalanmalarda zaman serisi dönemlerinin düzensiz olması ve periyodik olmamasından, dalgalanmaların uzun olmaları ve bilinmeyen sürelerle sahip olmasından dolayı mevsimsel dalgalanmalardan farklılaşırlar. Ele alınan zaman serisinde mevsimsel dalgalanmalar, düzensiz bileşen ve trend temizlenirse geriye kalan zaman serisi konjonktürel dalgalanmalar olarak ifade edilebilir. Konjonktürel dalgalanmaların hangi değişimleri göstereceği, değişim sonuçlarının nasıl olacağı, ne kadar vakit alacağı ve ne zaman konjonktürel dalgalanma olacağı, dalgalanmaların şeklini tahmin veya kontrol etmek zor hatta imkansızdır (Kaya, 2019, s. 12, s. 13).



Şekil 2.3. Konjonktürel Dalgalanma Gösterimi (Tüzen, 2012, s. 12)


Düzensiz bileşenler: Zaman serisinin dördüncü ve son bileşeni düzensiz bileşenlerdir. Düzensiz bileşenlerin meydana gelmesinde doğal olayların (deprem, sel gibi) ve sosyo-ekonomik olayların etkisi vardır. Düzensiz bileşen, zaman serisinin diğer bileşenleri olan mevsimsel, konjonktürel ve trend bileşenleri ile izah edilemez. Düzensiz bileşenler geçici ya da rastlantısal nedenler ile meydana gelmektedir. Bu sebepten dolayı da şiddeti ve hangi zamanda gerçekleşeceği öngörülemez (Horosan, 2011, s. 67).

2.1.4. Zaman Serisinin Sınıflandırılması

Zaman serileri aşağıdaki gibi sınıflandırılmıştır:

- Sürekli ve kesikli zaman serileri: Sürekli zaman serileri ele alınan verilerin ölçümlerine zaman faktörü dahilinde sürekli olarak sahip olabilen ve yoğunlukla aynı düzeyde olmayan zaman süreçlerinin meydana getirdiği ölçüm verilerinden oluşan zaman serileri olarak tanımlanırlar. Kesikli zaman serileri ise, yalnız belirlenmiş zaman süreçleriyle meydana gelen ve yoğunlukla aynı düzeyde olan zaman süreçlerinin meydana getirdiği ölçüm verilerinden oluşan zaman serileri olarak tanımlanırlar (Duru, 2007, s. 5).
- Durağan ve durağan olmayan zaman serileri: bir zaman serisi sabit ortalamaya, kovaryansa ve varyansa sahip ise bu tür zaman serilerine durağan zaman serisi olarak adlandırılır. İstatiksel açıdan durağanlık durumu tam tam sağlanıyorsa zaman serisi istikrarlıdır (Akşit, 2019, s. 29).

Durağan zaman serisine örnek olarak White noise(Beyaz gürültü) süreci örneği verilebilir (Kaya, 2019, s. 14).



Şekil 2.4. White Noise (Kaya, 2019, s. 15)

Eğer bir seri sabit olmayan ortalamaya, kovaryansa ve varyansa sahip ise yani zaman faktörüne göre herhangi bir farklılık gösteriyor ise bu tür zaman serilerine durağan olmayan zaman serisi olarak adlandırılırlar (Akşit, 2019, s. 29).

Durağan olmayan zaman serisine örnek olarak Random Walk(Rastgele yürüyüş) süreci örneği verilebilir (Kaya, 2019, s. 16).



Şekil 2.5. Random Walk Süreci (Kaya, 2019, s. 16)

- Mevsimsel ve mevsimsel olmayan zaman serileri: Zaman serilerinde alınan verilerin bir seneyi geçmeyecek şekilde tasarlanan ölçümlerin en yüksek ve en düşük bilgilere ulaşma yönelimine kısacası zaman süreçlerinin belirli yerlerinde bu ölçümlerin birbiri arasındaki korelasyon oluşumuna mevsimsel zaman serileri olarak tanımlanır (Akşit, 2019, s. 29, s. 30).
- Zaman serisi sınıflandırmalarını yapabilmek için ihtiyaçları karşılayacak miktarda ölçümlerin sağlanmış olması gereklidir. Sağlandığı takdirde zaman serisi verilerinin birbirlerini takip eden peş peşe sıralanmış senelerin aynı aylarında aynı davranışı gerçekleştiriyorsa bu seriye mevsimsel olmayan zaman serisi olarak adlandırılmaktadır (Duru, 2007, s. 8).

2.1.5. Zaman Serilerinin Analizleri

Zaman ile ilişkili verilerin, veri setinde bulunması ve veri setinin zaman serisi olması için gerekli bir koşuldur. Zaman serisi analizleri için kurulan modelde zamanın var olması modelin zaman serisi olduğunu açıklar. Ele alınan verilerin analizinde zamanla ilişkili bir biçimde başkalaşım geçirme hali incelenir (Akşit, 2019, s. 28, s. 29).

Zaman serilerinin analizi, matematiksel olarak bir modelin kurulması ve zamana bağlı olan tarihsel olarak dizilmiş verilerin ileriye yönelik bir tahminde bulunabilmesidir. Kurulan model, zaman serisi verilerini daha sorunsuz bir şekilde tahmin edilmesini sağlar. Zaman serisi analiz yöntemi ise, yanılığın çok düşük ve birbirleri arasında iç ilişki bulunmayan zaman serisi verilerine yaraşır bir matematiksel modelin gelmesine bağlıdır (Almahmud, 2019, s. 10).

Ele alınan zaman serisi verisinde konjonktürel dalgalanmalar, trend, mevsimsel bileşenler ve düzensiz bileşenler bulunabilir. Bu gibi bileşenlerin giderilerek zaman serisinden temizlenmelidir. Zaman serisi analizleri bu operasyon neticesinde veri setinde işlem yapabilmektedir (Güneş, 2010, s. 5, s. 6).

Toplamsal ve çarpımsal iki model zaman serilerinde bileşenlerin ayrışımında yer alır, Toplamsal model: $Y=T+C+S+I$,
Çarpımsal model: $Y= T*C*S*I$
Biçiminde ifade edilir (Çevik, 1999, s. 26).

Araştırmalarda yer alan zaman serileri sabit olduğu düşünülür. Fakat ele alınan çoğu zaman serisi sabit değildir. Sabit olmayan zaman serisini için birinci ya da ikinci dereceden farkı alındığında zaman serisi sabitleşir. Zaman serisinin varyansı, gözlem değeri, ortalaması sonsuza ilerlemesi, normal değerlerin üzerinde bir determinasyon kat sayısı (R^2) çıkması sabit olmayan bir seri üzerinde çalışma yapıldığını açığa kavuşturur. Bir problem olarak nitelendirilen bu durum iki değişkenin birbirleriyle bağlantısının doğrusal ilişkiden ziyade iki serinin aralarındaki ilişkinin trendlik anlamında güçlü olduğu savunulmaktadır (Kaya, 2019, s. 22).

2.1.6. Zaman Serisi Analizinde Kullanılan Bazı Temel Kavramlar

Zaman serisinde analiz işleminin uygulanabilmesi için birden fazla adım gerçekleştirilir. Bu analiz işlemlerindeki adımlardan daha fazla yararlanmak ve analiz işlemini tam anlamıyla gerçekleştirebilmemiz için istatistiksel ve matematiksel gibi konulardan bilgi sahibi olunması beklenir (Tüzen, 2012, s. 17).

Zaman serisi analizinde kullanılan bazı temel kavramlar vardır. Bunlar:

- Durağanlık
- Birim Kök Testleri
- Otokovaryans Fonksiyonu
- Otokorelasyon Fonksiyonu (ACF)
- Kısmi Otokorelasyon Fonksiyonu (PACF)

Durağanlık: Zaman serisi modellerini oluştururken, seriyi meydana getiren stokastik zaman serisinin, oluşan süre içerisinde değişmediği düşünülür (Akgül, 2003, s. 5). Böylelikle zaman serilerinde çözümleme yaparken, zaman serisinin durağan olduğu kabul edilir. Zaman serisini istatistiksel olarak analiz etmeye başlamadan önce, kullanacağımız zaman serisini başlangıç ve bitiş süresini kapsıyan dilimde durağan olup olmadığına bakılır (Göktaş, 2005, s. 5).

Örnek olarak, mevsimsel etki veya eğilim (trend) varsa bu serinin durağan olmadığı kabul edilir. Durağan olmayan seriler ise karşımıza bazı sorunlar çıkaracaktır. Bu seriler içerisinde en göze batanı, serilerin analizinde karşımıza çıkan, anlamlılık t testi ve modeldeki bileşenlerin birbirlerine bağımlı olup olmadığını söyleyen R^2 testinin değeri gerçek değerini tam olarak vermemesidir. Genel olarak R^2 testinin sonucu 0,9'dan yüksek ise model bileşenlerinin arasında ilişki olmadığı düşünülür. Bazen model bileşenlerinin birbirleriyle arasındaki bağımlılık ilişkisi olmasını beklemezken kuvvetli gözükabilir. Bunun sebebi olarak “mantıksız”(nonsensense) ya da “sahte”(spurious) regresyon olabilir. Bu nedenle, bileşenlerin birbirleriyle karşılaştırılması sahte regresyonu ortaya çıkarabilir. Eğer sahte regresyon var ise durağanlık durumu tekrardan gözden geçirilmelidir (Horosan, 2011, s. 68,69).

Bu olay, zaman serisinin değişkenlerinde trend faktörünün etkisi olduğunda ortaya çıkmaktadır (Ertek, 2000, s. 379).

Eğer R^2 değeri yeterince fazlaysa, t istatistiğinin anlamlılığından ve düşük Durbin Watson istatistiğinin anlam değerinden şüphelenilmelidir. Özellikle $R^2 > DW$ gibi bir durum ortaya çıkar ise sahte regresyonu tekrardan kontrol etmeliyiz. İkinci olarak durağan olmayan zaman serileriyle gelecek için bir öngörüleme işlemi yapıldığında istenilen sonucun çok ötesinde bir sonuç verecektir (Horosan, 2011, s. 69).

Birim Kök Testi: Zaman serilerinin durağanlı Kabul mu yoksa ret mi ettiğini ya da durağanlığı kaçınıcı dereceden terk ettiğini öğrenmek için başvurulmuş yöntemin adı birim kök testleridir. Durağanlığı reddeden zaman serilerinde birim kök bulunur. Burada ki birim kök değeri, zaman serisinin durağanlaştırılana kadar alınacak olan fark sayısını belirtir. Eğer zaman serisi, birim kök testini bir kez uyguladığında durağanlaşıyor $I(1)$ şeklinde ifade edilir. Eğer serinin d kez farkı alınıp durağanlaşıyorsa, d seviyesinden durağandır denilmektedir ve $I(d)$ şeklinde ifade edilir. Eğer hiç farkı alınmıyor ise seri durağan olarak kabul edilir (Kaya, 2019, s. 24).

En yaygın kullanılan birim kök testleri aşağıdaki gibidir:

- Genişletilmiş Dickey Fuller Testi (ADF)
- Phillips-Perron Testi (PP)

Genişletilmiş Dickey Fuller Testi: Dickey-Fuller testinin hipotezlerinde $H_0: p \geq 1$ ise serinin durağan olmadığı, $H_1: p \leq 1$ ise serinin durağan olduğu kabul edilir. Genişletilmiş Dickey Fuller testini ortaya çıkışı ise 1984'de Said ve Dickey'in ortak yayımladığı makaleye dayanmaktadır. Dickey-Fuller testinin mantığında hata terimi olarak alınan ε_t 'nin otokorelasyon olmadan ve varyansında sabit olarak alınmasıyla gerçekleştirilir. ADF testi ε_t 'nin otokorelasyonlu olduğu düşünülerek gerçekleştirilir. Birbirine bağlı olan γ_t değişkenin gecikmeli değerleriyle kurulan modele, bağımsız bileşen olarak eklenir. Bunun sebebi, hata terimlerinde otokorelasyonun yaratacağı sıkıntılı durumun etkisini yok edecek kadar, gecikmeli fark terimini yaratılır ve

modele eklenir. Otokorelasyon fonksiyonun sıkıntısı, kaçınıcı gecikmeli γ_t değeriinde etkisini kaybediyorsa o sayı optimum gecikme sayısı olarak adlandırılır. Optimum gecikme sayısının belirlenmesine etki eden değeriiler ADF testi sonuçlarında Akaike Bilgi Kriteri (AIC) ve Schwarz Bilgi Kriteri(SIC)'dir. Bu değeriileri elle hesaplamak yerine paket programlarda otomatik olarak hesaplanmaktadır. ADF testi uygulandığıında ortaya çıkan sonuçları MacKinnon'un kritik değeriileri ile karşılaştırılır. Zaman serisinin durağanlığı kabul etmesi H_0 'ın reddedilmesiyle ortaya çıkmaktadır (Kaya, 2019, s. 26,27).

Phillips-Perron Testi: DF ve ADF testlerinde hata terimlerinin beyaz gürültüsü olduğu düşünülür. Yani hata terimlerinin birbirleriyeel bağlantısının olmadığı ve her dilimde aynı olduğu kabul edilir (Üçler, 2011, s. 165). “Bu testin alternatifi olarak P-P durağanlık sınımasında hata terimlerinin değeriışen varyanslı hali ele alınmış; başka bir deyişle,ADF testindeki varsayımlar yumuşatılmıştır (Üçler, 2011, s. 165)” PP testinde, hata değeriışkenlerinde sırasıyla devam eden serilerin arasındaki bağlantıları dikkate almak için γ_{t-1} (gecikmeli fark)'de işin içine katmadan nonparametric istatistiki metoda başvurulur. Zaman serisindeki hata terimleri arasındaki bağlantıyı belirlemek için parametric olmayan düzeltmeden yararlanılır. Bu duruma Newey-West hata düzeltmesi denir. Bu test hata değeriışkenlerinin birbirine zayıf bağlantısı olması ve her yere eşit dağılmasını da sağlayarak otokorelasyon sorununu ortadan kaldırmaktadır. Özellikle, eğilime sahip zaman serilerinde PP testi DF testine göre daha güçlüdür (Kaya, 2019, s. 27,28).

Otokovaryans Fonksiyonu: Zaman serisini birleştiren sürecin açıklanabilmesi için zaman serisi süreçlerinde ki olasılık dağılımının tamamlandıktan sonra belirtilmesi gerekmektedir. Fakat bu durum her zaman böyle olmamaktadır. Zaman serisinin bu süreçteki özelliklerini belirlenmesi gerekmektedir. Bunun için de otokovaryans fonksiyonu, otokorelasyon fonksiyonu ve kısmi otokorelasyon fonksiyonları kullanılır (Biçen, 2006, s. 14). Zaman serisi incelemelerinde otokovaryans ve otokorelasyon fonksiyonları en önemli yöntemlerdendir. Bu fonksiyon zaman serilerinin durağanlığını tespit etmeye ve zaman serisi modellerinin tespit edilmesinde işe yaramaktadır (Akıl, 2019, s. 4). Zaman serisinin otokovaryansının güvenilir olması gerekmektedir. Bunun için fazlasıyla gözleme ihtiyaç duyulur.

Çünkü gecikmede ki sayımız arttıkça kaybedilen gözlem sayısı da artacaktır. Böylelikle gözlemdeki azalışla beraber gözlem sayımızda azalacaktır ve tahminlerdeki yapılabilecek hata oranlarımızda artıracaktır (Kaya, 2019, s. 29).

Otokorelasyon Fonksiyonu(ACF):Otokorelasyon katsayıları aslında zaman serisinin farklı dilimlerinde izlenen gözlemlerin birbirleriyle olan bağlantının katsayısını gösterir. Bu katsayılar zaman serileri için önemli bir ölçüttür. Otokorelasyon katsayıları, zaman serisi modellerinde geçmişte olan verilerin birbirleriyle ne kadar bağımlı olduğunun derecesini sayısal olarak belirtir (Tüzen, 2012, s. 24). Otokorelasyon katsayılarının yüksek olması zaman serisindeki değişkenlerin geçmişle bağlantılı olduğunu söyler. Düşük olması ise bunların tesadüfi olduğunu söyler (Göktaş, 2005, s. 9). Otokorelasyonm fonksiyonunun sonuçları eğer hızlı bir biçimde negatife yaklaşırsa ve kısa sürede eksenini kesiyorsa serinin durağanlığı Kabul ettiğini, eğer sonuçlar yavaş yavaş azalırsa ve uzun dönemde eksenini kesiyorsa serinin durağanlığı reddedildiğine karar verilmektedir (Akgül, 2003, s. 15).

Kısmi Otokorelasyon Fonksiyonu(PACF):Kısmi otokorelasyonlar otokorelasyonlara benzemektedir. İkiside zaman serilerinin iki noktasındaki ilişkiyi değerlendirmek için kullanılan istatistiksel ölçüdür. Otokorelasyon fonksiyonu, zaman serilerinde belirlenen noktalar arasındaki ilişkiyi sayısal olarak görmeyi sağlar. Bazen bu belirlenen iki noktaların arasındaki bağlantılar araştırılırken arasında kalan zaman serisinin gözlemlerinin hiçe sayılmaktadır. Fakat burada hiçe sayılan gözlemler bize zaman serisi hakkında daha fazla bilgi edinmemizi sağlar. Bu şekilde belirlenen fonksiyonun adı kısmi otokorelasyondur. Zaman serilerinde $Y_t - Y_{t-k}$ korelasyonunun büyük bir kısmının aslında $t-1, t-2, t-3, \dots$ gibi değerler taşımaktadır. Bu değerlerden ayrıştırılarak ortaya çıkan sonuçları kısmi otokorelasyon fonksiyonları olarak adlandırırız. Ayrıca pacf değerleri acf değerlerinden de üretilebilmektedir (Tüzen, 2012, s. 26). Hem acf hem pacf değerleri tahminleme yöntemlerinde zaman serileri hakkında durağanlığı belirtme, fark alma derecesi, mevsimsellik ilişkisini, trendlik ilişkisini, modelin seçiminde tahminler, ayırt edici kontrol ve hata terimlerinin analizi sırasında kullanılır (Akgül, 2003, s. 27).

2.1.7. Zaman Serileri Analizin Kullanılan Yöntemler

Zaman serisi modellerinin geleceğe yönelik bir öngörüleme işlemini daha sağlıklı yapabilmesi için zaman serisi modellerinin tek değişkenli ve çok değişkenli olarak iki tür belirtilmiştir. Tek bir zaman serisinin için tek verimiz varsa tek değişkenlik, birden çok ise çok değişkenli olarak adlandırılır (Horosan, 2011, s. 98).

Çok Değişkenli Zaman Serileri İle İlgili Tahmin Yöntemleri: Zaman serisi modellerinde çok değişkenli zaman serileri yöntemleri iki veya daha çok zaman serilerinin kendi aralarında sebep sonuç ilişkisi belirtilir. Bu sebep sonuç ilişkisi kullanılarak öngörüleme ve kontrol amacı için kullanılır (Duru, 2007, s. 10). Çok değişkenli zaman serisi ve normal zaman serisi tahminlemeleriyle ilgili bir çok şeyin bilindiği varsayılmaktadır. Fakat bunlara her zaman sahip olunamamaktadır. Bu yüzden, gelecek ile alakalı tahminlerde genellikle tek değişkenli zaman serileri daha güvenilir sonuçlar vermektedir (Çevik, 1999, s. 29). Bu sebeplerden dolayı çok değişkenli zaman serilerinin tahmin yöntemleriyle ilgili daha fazla detaya girilmemiştir.

Tek Değişkenli Zaman Serileri İle İlgili Tahmin Yöntemleri: Tek değişkenli zaman serisi modellerinin tek bir mantığı vardır. Öncelikle zaman serisinde istenilen gelecek değer hesaplanır, sonrasında ise gelecek için hesaplanan değer ile gelecekteki değerleri öngörüleme işlemi yapılır (Biçen, 2006, s. 44).

“Tek değişkenli zaman serileri ile ilgili tahmin yöntemlerinin dayandığı üç önemli varsayım vardır (Çevik, 1999, s. 30).” Bunlar:

- Zaman serisine etki eden etkilerin gelecekte de sabit olacağı düşünülür. Bu sayede geçmiş verilerden yola çıkılarak gelecek için tahminleme yapılabilir (Çevik, 1999, s. 30).
- Bu metodlar, önceden belirlenen zaman aralıklarıyla elde edilen sonuçların ortaya çıkardığı sonuçlar süresiz olan zaman serisine uygulanır (Çevik, 1999, s. 30).

- Elimizde olan yöntemler, zaman serisin ortaya çıkara bu unsurların birbirleriyle bağlantılarını ve tesadüfen olma olasılıklarından arındırılarak gelecek zaman dilimleri için değer öngörülemesi yapmayı hedefler (Çevik, 1999, s. 30).

Tek değişkenli zaman serilerini tahminleme yöntemleri vardır. Bunlar:

- Trend Analizi Yöntemi
- Hareketli Ortalamalar Tahmin Yöntemi
- Üstel Düzgünleştirme Tahmin Yöntemi
- Box-Jenkins Tahmin Yöntemi

Trend Analizi Yöntemi: Zaman serisi modellerinin tahminlemesinin etki eden bir diğer unsur ise trend faktörüdür. Geleceğe yönelik tahminleme yaparken fazlasıyla başvurulan bir yöntemdir. Zaman serisinin kapsadığı dönemler incelendikten sonra, bu zaman serilerinde genel bir ilerleme eğilimi gösteren trend eğrisi denkleme bulmaya çalışılır. Zaman serilerinde trend analizi iki sebepten oluşmaktadır. İlk olarak trendin kendisini araştırmaktır. Bu araştırma yapıldıktan sonra, trend katkısıyla serisini genel bir eğilimi belirlenir ve bundan yola çıkılarak gelecek için öngörüleme yapma olanağı sağlar. Bununla beraber trende etki eden diğer unsurların belirlenmesine yardımcı olacaktır ve başka bir trendle kıyaslaması yapılacaktır. İkinci olarak ise, sapmaların ölçülmesini sağlayacaktır (Duru, 2007, s. 11).

Hareketli Ortalamalar Tahmin Yöntemi: Hareketli ortalamalar tahmin yöntemi aslında, zaman serilerinde belirlenen gözlem değerleri, kümeler halinde şekillendirilerek, şekillenen her küme için aritmetik ortalaması hesaplanmaktadır. Ortalaması hesaplanan her bir kümenin en sonundaki terimi takip eden terimin tahmin olarak kabul etmesidir (Çevik, 1999, s. 32). Bu yöntemi uygulayabilmek için, trendin doğrusal bir eğime sahip olması, dalgaların boylarının eşit ve dalgaların şiddetleri de aynı olmalıdır. Bu yöntem, uzun süre zaman serilerinin tahmini için pek uygun değildir. Çünkü, tahminlemelerdeki güven seviyelerinin az olmasındandır (Çevik, 1999, s. 32,33; Duru, 2007, s. 11,12; Kaya, 2019, s. 33).

Üstel Düzgünleştirme Tahmin Yöntemleri: Üstel düzgünleştirme yöntemlerinde, zaman serisinde bulunan geçmiş dönemdeki verilerin hepsinin ağırlıklarının aynı olduğu basit hareket ortalamalar yöntemine benzeyen fakat geçmiş dönemdeki verilerin ağırlıklarının birbirinden farklı verildiği bir yöntemdir (Çuhadar, 2006, s. 78). Üstel Düzgünleştirme yöntemlerinde geçmiş dönemlerdeki verilerden, yakın olanlara daha fazla ağırlık verilir uzakta olan verilere ise daha düşük verilmesi mantığından geçer. Bunun sebebi zaman serisindeki son dönemde verilerin geleceğin tahminine daha çok etki ettiğini düşünülür. Bu özelliğiyle basit hareketli ortalamalar yönteminden ayrılmaktadır (Çuhadar, 2006, s. 78,79). Üstel düzgünleştirme yöntemleri kendi içinde bazı tahminleme yöntemlere ayrılmıştır. Bunlar:

- Basit Üstel Düzgünleştirme Yöntemi
- Holt Trend Yöntemi

Basit Üstel Düzgünleştirme Yöntemi: Üstel düzgünleştirme yöntemi mevsimsellik ve trend etkisi olmayan basit zaman serisi modellerinde kullanılmak üzere C.C. Holt tarafından 1958 yılında geliştirilmiştir. Bu yöntemin zaman serilerinde kullanılması için üzerinde geliştirme yapan kişi de Brawn'dır. 1960'lı yıllarda mevsimsellik etkisinde olduğu zaman serilerinde kullanılması için Winter bu yöntemi daha da geliştirmiştir (Çevik, 1999, s. 33; Akgül, 2003, s. 98; Kaya, 2019, s. 33). Basit üstel düzgünleştirme yönteminde, zaman serisinde trend ve mevsimsellik etkisi olmadığını (Orhunbilge, 1999, s. 95), bununla beraber zaman serisini ortalamasının çok yavaş değiştiği, yani zaman serisinde meydana gelen dalgalanmaların tesadüfi bir hata olduğu düşünülmektedir (Can, 2009, s. 72).

Holt Trend Yöntemi: Bu yöntemin bir diğer ismi Holt'un iki parametrelili doğrusal üstel düzgünleştirmedir. Zaman serilerinin bir çoğunda verilerin uzun süreçte yukarı veya aşağı doğru bir trendin olduğu görülmektedir. Üstel düzgünleştirme yöntemlerinde bu zaman serilerinin tahmininde kullanılmasıyla negative sapmalı bir tahmin ortaya çıkmaktadır. Holt trend metodunda zaman serisinin mevsimsel etkisi olmayıp doğrusal bir trend eğiliminin olduğu zamanlarda tahminleme için iyi sonuçlar verdiği kabul edilmiş olan bir yöntemdir (Can, 2009, s. 76).

Box-Jenkins Tahmin Yöntemi: Zaman serilerinin veri analizinde sıklıkla tercih edilen yöntemlerinin başında gelmektedir. Box-Jenkins tahmin yönteminin çok tercih edilmesi, analizde ele alınan herhangi bir zaman serisi verilerini sabit olup olmaması, mevsimsellik içerip içermemesi durumu fark etmeksizin bilgisayar paket yazılımları veya programlarıyla sonuca ulaşabilmesidir. Verilerin analizi için zaman serilerinde kullanılan Box-Jenkins tahmin modelleri, aynı zamanda ARIMA modeller olarak da anılmaktadır (Güneş, 2010, s. 15).

Box-Jenkins tahmin yöntemi, tek değişkenli zaman serilerinin tahmini için bu araştırmada dolar kurunun tahmininde kullanıldığından devam eden bölümlerde detaylı olarak anlatılmıştır.

2.2. Makine Öğrenmesi

Makine öğrenmesi terimi ilk olarak 1950 yılında Turing tarafından “Makineler öğrenebilir mi?” sorusuna aradığı cevap ile ortaya atılmıştır. Bu sorudan sonar birçok araştırmacı makinelere farklı öğrenimler kazandırarak uygulama alanları geliştirmişlerdir (Turing, 1950).

Makine öğrenmesi 1959 yılında Arthur Samuel tarafından “Bilgisayarlara öğrenme yeteneğinin kazandırıldığı yöntem” olarak tanımlamıştır (Simon, 2013).

Makine öğrenmesi projelerindeki amaçlardan birisi geçmiş verileri kullanarak gelecek için bir tahminde bulunmaktır. Bu problemleri çözmek için makine öğrenmesi yöntemleri geliştirilmiştir. Makine öğrenmesi yöntemleri geçmiş verileri kullanarak oluşturulacak yeni veriler için en uygun modeli oluşturmaya çalışır (Alpaydın ve Bach, 2014).

Makine öğrenmesi, doğru tahminler yapmak için verileri kullanan sayısal metotlar olarak tanımlanabilir. Bu veriler insan tarafından oluşturulmuş olabileceği gibi çevre ve etkileşim kurularak elde edilmiş farklı bilgi çeşitleri de olabilir. Tahminlemenin başarılı olabilmesi açısından bilginin kalitesi ve boyutu önemlidir (Mohri ve diğerleri, 2012; Alpaydın ve Bach, 2014).

Makine öğrenmesinin gerçek hayattaki uygulamalarına örnekler; ses tanıma sistemleri, yüz tanıma sistemleri ve robotiktir. (Mitchell, 2006).

2.2.1. Makine Öğrenmesi Çeşitleri

Makine öğrenmesi algoritmaları öğrenim özellikleri bakımından iki ana başlıkta incelenir. Bunlar:

- Denetimli Öğrenme
- Denetimsiz Öğrenme

Fakat bu iki öğrenmenin dışında birçok öğrenme yöntemleri de vardır. Bunlar:

- Yarı denetimli öğrenme
- Takviyeli Öğrenme

bu yöntemlerden bazılarıdır (Bell J., 2014).

Denetimli Öğrenme: Denetimli öğrenmede veri setinin girdileri ve çıktıların olması gereklidir. Verileri ve sonuçlarını eğitim verisi olarak makineye vererek, girdi ve çıktı verileri arasındaki bağlantıyı çözmesini ve bir fonksiyon üretmesini sağlamaktadır (Bell J., 2014) .

Denetimli öğrenme: Veri setinden faydalanarak öğretilen değer ile gerçek değer arasındaki farkı en aza indirmeye çalışır. Hata farkı bir girdinin algoritma tarafından oluşturulmuş değer ile gerçek değer arasındaki fark olarak tanımlanabilir. Öğretilme aşamasında oluşan hata farkı tespit edilerek daha önceden belirlenmiş olan hata eşik değeri ile karşılaştırılır. Sistem eşik değerine ulaşana kadar eğitim devam eder ve eşik değerine ulaştığında eğitim sona erer. Denetimli öğrenme çıktıları regresyon veya sınıflandırma olabilir (Mohri ve diğerleri, 2012).

Denetimsiz Öğrenme: Denetimsiz öğrenmede veri örneklerinin etiket bilgisi yoktur. Verilerin uzaklık, benzerlik gibi değerlerine göre kümeleme yapılır (Alpaydın ve Bach, 2014). Denetimsiz öğrenme algoritmaları büyük veri içerisindeki gizli örüntüleri bulmaya çalışır. Bu öğrenme yöntemi için doğru ya da yanlış bir çözüm yoktur, verilerin sürekli işlenerek ortaya çıkarılması ve bir bütünlük oluşturulması amacı vardır (Bell J., 2014).

Kümeleme ve Boyut Azaltma denetimsiz öğrenme algoritmalarının temel amaçlarındandır. Tekil Değer Ayırıştırması, Korelasyon analizi, Temel Bileşen Analizi, Hiyerarşik Kümeleme, faktör analizi, k-ortalama kümeleme denetimsiz öğrenme yöntemlerinden bazılarıdır (Mohri ve diğerleri, 2012).

Kümeleme farklı kategorilere ait benzer verileri benzer olmayan kümelere dahil ederek birbirinden ayırma işlemidir. Tahmin edici modellerde düzenli veri grupları oluşturulması için kümeleme işlemi ön veri işleme metodu olarak kullanılabilir (Alpaydın ve Bach, 2014).

Yarı Denetimli Öğrenme: Bu öğrenme yönteminde denetimli ve denetimsiz öğrenme birlikte kullanılır. Kullanılan veri setindeki verilen büyük çoğunluğunu denetimsiz öğrenme yönteminde olduğu gibi etiketleme bilgisi bulunmayan girdi değişkenleri oluşturur. Veriseti içerisinde etiketlenmiş ve etiketlenmemiş veriler bulunmaktadır. Genellikle etiketlenmemiş veri sayısı etiketli veri sayısından daha fazla miktardadır. Tüm etiketlenmemiş verileri de etiketlemek zordur. Bir öğrenme problemi için etiketlenmiş verilerin elde edilmesi çoğu zaman vasıflı bir insan ajanının gerektirir. Etiketleme işlemiyle ilişkili maliyet, böylece etiketlenmemiş verilerin elde edilmesinin nispeten ucuz olmasına rağmen, tamamen etiketlenmiş bir eğitim setinin olanaksız hale getirilmesine neden olabilir. Yarı denetimli öğrenme yöntemi regresyon, sınıflandırma, sıralama gibi birçok farklı problemi çözmek için kullanılabilir (Mehryar Mohri, 2012; Chapelle ve Schölkopf, 2006).

Takviyeli Öğrenme: Sisteme beklenen sonucun tam olarka verilmediği durumlar için geçerlidir. Sistemler karşılaştıkları eylemler karşısında kendisini adapte ederek çevreden gelen iyi değerlendirme sonuçlarını maksimize etmeye çalışır. Eğitim ve

test aşamalarının birlikte yaptığı bu yöntemde sistem denetçi ile sürekli ilişki içerisinde. Sistemin ürettiği sonuçları için çevreden alınan geri beslemeler algoritmaya yol gösterir ve sistem bu şekilde adım adım modeli öğrenir (Sutton ve diğerleri, 1998).

2.2.2. Makine Öğrenmesi Uygulama Alanları

Makine öğrenmesi bilgisayar sistemlerine tahmin yapma, bilgi sunumu, planlama ve öğrenme gibi işlevleri sağlamak için kullanılan bir bilgisayar bilimi alanıdır. Günümüzde yapay zekâ sistemlerine artan ihtiyaç sebebiyle artık birçok alanda makine öğrenmesi algoritmaları kullanılmaktadır. Mühendislik, eğitim, sağlık, bankacılık, finans, güvenlik vb. alanlar bu algoritmaları kullanan bazı sektörlerdir (towardsdatascience.com, 2019).

Makine öğrenmesi algoritmalarının en yaygın olarak kullanıldığı yöntemlerden birisi de tahmin yapmaktır. Verileri toplamak ve bir sonucu tahmin etmek kararların daha hızlı ve daha doğru şekilde alınması sağlamaktadır. Bu projemizde ise geçmişteki dolar kuru verilerini analiz ederek gelecek dolar kuru hakkında bir tahmin oluşmak istenmiştir. Böylece dolar kurunun gelişimini tahmin edilecek ve yatırımlar yapılacaktır (Jahnke, 2015).

2.2.3. Makine Öğrenmesi ile Tahmin Yapma

Tahmin, ekonomi, bilim, eğitim, sağlık, doğa vb. alanlarda yapılan sezgisel ya da eldeki verilere dayanarak, düşünce ve uzağı görme, geleceği yaklaşık olarak değerlendirme şeklinde tanımlanır (Kolassa ve Siemsen, 2016).

İnsanlar için tahmin yapmanın hayatında her zaman bir yeri vardır. En basit örnek olarak havanın bugün yağmurlu olup olmayacağını tahmin ederek duruma göre giyecekleri elbiseleri belirlemek hayatın içinde ki en basit tahminlemelerden birisidir. Makine öğrenmesi kullanılarak bu tahmin işlemlerini daha doğru ve kesin bir sonuç ile ortaya çıkarmak mümkündür (Üreten, 2005).

Makine öğrenmesi sınıflandırma, regresyon, kümeleme gibi işlemler için kullanılmakla beraber zaman serisi analizi için de sıklıkla kullanılmaktadır. Makine öğrenmesi ve zaman serileri geçmişten gelen bilgiler doğrultusunda yeni tahminler yapmaya çalışır. Bu makine öğrenmesinde denetimli öğrenme çeşididir (Türkoğlu, 2007). Bu projede ise en çok bilinen makine öğrenmesi metotlarından Yapay sinir ağları sınıflarından yineleyen sinir ağlarının bir türü olan LSTM kullanılarak bir tahmin işlemi yapılmıştır.

2.2.4. Makine Öğrenmesi Uygulama Süreci

Bir problem makine öğrenmesi algoritmaları ile çözülmesi için takip edilmesi gereken adımlar vardır. Problemin başarıyla çözülebilmesi için bu adımların sırasıyla uygulanması gerekir (Bell J., 2014). Bu adımlar;

- Problemin Tanımlanması
- Verilerin toplanması
- Verilerin Hazırlanması
- Modelin Çalıştırılması
- Sonuçların Raporlanması

Problemlerin Tanımlanması: İlk aşama olarak problemin tanımlanması yapılır. Yani bir problemin neden çıktığı, problemin çözümündeki beklentiler, iş süreçlerinde problem ile ilgili veri kaynakları ve veri akışları tespit edilir. Problemin çözümü sonunda hangi çıktıların beklendiği tanımlanır (Karasar, 2005).

Bir problemin makine öğrenmesi algoritmaları ile çözülebilmesi için öncelikle problemin iyi tanımlanması gerekir. Belirlenen amaç, problem üzerine odaklanmış ve açık bir dille ifade edilmiş olmalıdır. Öyle ki, bir problemin iyi tanımlanması çözülmesinden daha çok önem arz eder. Problemi tanımlarken şunlar göz önünde bulundurulmalıdır (Bell J., 2014):

- Çözümün neden önemli olduğu,
- Çözümün getireceği faydalar,

- Problemin ortaya çıkardığı zararlar.

Verilerin Toplanması: Probleme uygun olarak veriler toplanır veya mevcut verilerin üzerinden geçilir. Genelde bu adıma başlanmadan önce problemin tanımının doğru yapılması oldukça önemlidir. Problemin tanımlanması aşamasında en çok yapılan hatalardan birisi eldeki verinin gereksiz yere işlenmesidir (Shearer, 2000). Probleme uygun olan verilerin toplanması için internet üzerindeki kaynaklardan yardım alınabilir. Örnek olarak bu proje için dolar kuru verileri TCMB sisteminin web sitesinden alınmıştır.

Makine öğrenmesinde başarılı bir uygulama yapabilmek için toplanan verilerin sağlıklı veri olması gereklidir. Toplanan verilerin formatı, niceliği, konu başlıkları gibi unsurlar dikkatle incelenmelidir. İstatistiksel ve grafiksel analizler yapılarak veriler incelenmelidir. Önemli olan toplanan verilerin analiz için yeterli olup olmadığıdır (Bell J., 2014).

Verinin Hazırlanması: Verinin hazırlanması aşamasında veri üzerinde yapılacak işlemlere ve bu işlemlerin hangi yöntemlerle yapılacağına karar verilir toplanan veri model oluşturma işlemine hazır hale getirilir (Rahman ve Davis, 2013). Verinin hazırlanması aşağıdaki aşamalardan oluşur:

- “Verinin seçilmesi aşamasında elde olan verilerden hangilerinin modelleme sırasında kullanılacağı belirlenir
- Verinin temizlenmesi aşamasında modelin oluşmasına engel olabilecek veya modeli bozabilecek veriler çıkarılır. Bazen de eksik veriler bir model aracılığıyla tahmin edilerek yerine konur
- Verinin hazırlanması aşamasında, mevcut veriler kullanılarak yeni veri alanları oluşturulur
- Verinin entegrasyonu aşamasında farklı kaynaklardaki veriler birleştirilir
- Verinin biçimlendirilmesi aşamasında veriler modelleme için ihtiyaç duyulan biçime getirilir (Rahman ve Davis, 2013).”

Modelin Çalıştırılması: Problem tanımlandıktan sonra çözüm için veri toplama aşamasına geçilir. Toplanan veriler işlendikten sonra kullanıma hazır hale gelir. Çözüm için kullanılacak olan algoritmalar belirlendikten sonra veriler eğitime başlanır. Kullanılan algoritmalar arasından çözüm için en iyi performansı veren modeller çözüm için kullanılır. Model çalışırken eğer bir sorun yaşanırsa geriye dönülerek adımlar tekrar gözden geçirilir ve gerekli düzeltmeler yapılarak model tekrar çalıştırılır. Sorunlar tamamen çözülene kadar ve model sorunsuz şekilde çalışana kadar bu işlemler tekrar tekrar uygulanır (Bergmeir ve Benitez, 2012).

Sonuçların Raporlanması: Bu aşamada, buraya kadar olan adımların genel bir değerlendirmesi yapılır ve problemin çözümünde ne ölçüde başarı sağlandığı test edilir. Sonuçlar grafiklerle veya raporlarla gösterilir ve incelenir (Hague, 2011).

2.2.5. Makine Öğrenmesi Algoritmaları

Makine öğrenmesi algoritmaları arasında en çok kullanılan algoritmalar bunlardır:

- Naive Bayes Algoritması
- Karar Ağaçları
- Yapay Sinir Ağları
- Zaman Serisi Analizi
- K-En Yakın Komşu(KNN)'tır (Brownlee J., 2016).

Bu çalışmada ise yapay sinir ağları yönteminin bir sınıfı olan LSTM kullanılmıştır.

Naive Bayes Algoritması: Naive bayes yöntemi, Bayes teoremi kullanılarak oluşturulmuş bir olasıksal bir algoritmadır (Kızılkaya ve Oğuzlar, 2018).

Bayes teoremine göre, bir sınıflandırma probleminde oluşabilecek bağımlı durumların olasılıkları şu şekilde hesaplanabilir (Rish I., 2001).

$$P(w|X) = \frac{P(X|w)P(w)}{P(X)}$$

Karar Ağaçları: Karar ağacı algoritması, sınıflandırma problemlerinde en çok kullanılan algoritmalarından birisidir ve bilgi teorisi ilkelerine dayanmaktadır (ALAN, 2014). Diğer algoritmalar ile kıyaslandığında karar ağaçlarının yapılması ve anlaşılması daha kolaydır. Karar ağaçları ayırık parametrelerden oluşur ve gürültüye dayanıklı bir yapıya sahiptir. Karar ağaçları bileşenleri düğümler ve yapraklardır. Düğümler, verilerin hangi yönde gideceklerini gösterirken, yapraklar verinin sınıfını gösterir (Maindonald ve Braun, 2006).

Karar ağaçları kök ile başlar. Veriler düğümlerden geçerek dallara ayrılır ve yapraklara ulaşır. Düğüm sonucunda verilen karar çeşitliliğine göre dallar oluşturulur. Son olarak işlenen dallar yapraklara giderek sonuç değerlerine ulaşır (Bell J., 2014).

Ağaç yapısındaki her dal bir kural içeren fonksiyonlardır. Yeni dal oluşumu sırasında sınıflandırma bitmemiş ise yeni bir düğüm oluşturulur ve yeni kurallar yazılır. Ağaç sonucunda oluşan düğümlerin sayısına derinlik ismi verilir. Derinlik sayısı verilerin büyüklüğüne ve homojenliğine bağlıdır (Carvalho ve Freitas, 2004).

Karar ağaçlarının yönetimindeki dikkat edilmesi gereken en önemli nokta düğümlerin kök düğümünden itibaren hangi kurallarla ve nasıl dallanacağına karar vermektir. Bu işlemler için kullanılan karar ağacı algoritmaları vardır. Bunlar ID3, CART, C5.0, C4.5, Rastgele Orman gibi algoritmalar (Breiman, 2001; Kass, 1980; Quinlan, 1986).

K- En Yakın Komşu (KNN): KNN, 1968 yılında Cover ve Hart tarafından önerilmiştir. Sınıflandırma problemini çözen denetimli öğrenme algoritmalarından birisidir. Diğer yöntemlere bakarak daha kolay uygulanır bu sebeple literatürde yer alan makine öğrenmesi projelerinde popüler bir algoritmadır. Bu tip algoritmalarda eğitime gerek yoktur. KNN, mevcut verileri depolayan ve yeni verileri özelliklerine göre sınıflandıran bir algoritmadır (Pilavcılar, 2007; Jiang ve Zhou, 2004).

KNN yeni verilerin değerlerini tahmin etmek içinde kullanılır. Seçilen bir çeşit özelliğin kendine en yakın özellikle arasındaki yakınlığı kullanarak sınıflandırma yapılır ve verilerin benzerliklerini kullanarak tahmin eder (Kılınç ve diğerleri, 2016).

KNN algoritması, sınıflandırmaları yapabilmek için uzaklık teoremlerini kullanır (Manning ve Schutze, 1999).

Bunlar;

$$\text{Öklid Teoremi} = \sqrt{\sum_{i=1}^k (x_i - y_i)^2}$$

$$\text{Manhattan Teoremi} = \sqrt{\sum_{i=1}^k |x_i - y_i|}$$

$$\text{Minkowski Teoremi} = \sum_{i=1}^k (|x_i - y_i|)^q)^{1/q}$$

Yapay Sinir Ağları: Yapay sinir ağları, insandaki sinir sistemini oluşturan ağlardan ilham alınarak geliştirilmiş bir bilgi işleme sistemidir. Süreç içerisinde kendi kendine öğrenebilen ve karar verebilen bir algoritmaya sahiptir. Klasik yöntemlerden farklı olarak yapay sinir ağları çalışma yapısıyla doğrusal olmayan yapıdaki problemlerin çözüm aşamasında oldukça başarılıdır. Daha önce gerçekleşmemiş olayların çözümünü öğrenme özelliğiyle girdi ve çıktılar arasındaki sonuca bakarak sonuç üretmektedir (Sağıroğlu, Beşdok ve Erler, 2003; Liliana ve Napitupulu, 2012; Mehrotra ve diğerleri, 2000) .

Yapay sinir ağları, önceki verilerden faydalanarak olayları öğrenebilen bir makine öğrenmesi algoritmasıdır. Öğrenme, gruplandırma, ilişkilendirme gibi özellikleriyle insan beynine benzer bir şekilde model oluşturabilirler. Bu özellikleri sayesinde gerçek hayattaki birçok problemi çözebilirler. En önemli işlevi girdi verilerine karşı çıktı verilerini belirlemesidir. Yapay sinir ağları doğrusal modellerden farklı olarak belirsizlik durumunda bile eğitildikten sonra modellemeyi sağlayabilmektedir (Öztemel, 2003; Zhang ve diğerleri, 1998).

Yapay sinir ağıları verileri örnekleriyle birlikte toplar ve genellemeler yaptıktan sonra daha önce karşılaşmadığı durumlarla karşılaştığı zaman onlara karşı daha önceden öğrenmiş olduğu bilgileri kullanarak problemlere karşı bir yargı verebilir (D. Silver, 2016). Bu özellikleri sayesinde literatürde pek çok alanda tercih edilmeye başlanmış ve karışık problemlere karşı gayet başarılı sonuçlar göstermiştir (Fausett, 1994).

Zaman Serisi Analizi: Makine öğrenmesi algoritmaları birçok farklı alanda tahminleme yapmak için kullanılmaktadır. Zaman serisi analizi ise bu algoritmalarından birisidir. Zaman serileri analizi ile tahmini yapılacak veri setinin geçmiş dönemdeki değerleri kullanılarak, çeşitli yöntemlerle tahmin modeli elde edilerek gelecek dönem değerleri hakkında tahmin yapılabilir (Allen, 1964; Grim ve Gradvohl, 2018).

BÖLÜM 3. ÖNERİLEN ÇÖZÜM MODELİ

3.1. Box-Jenkins Tahmin Yöntemi

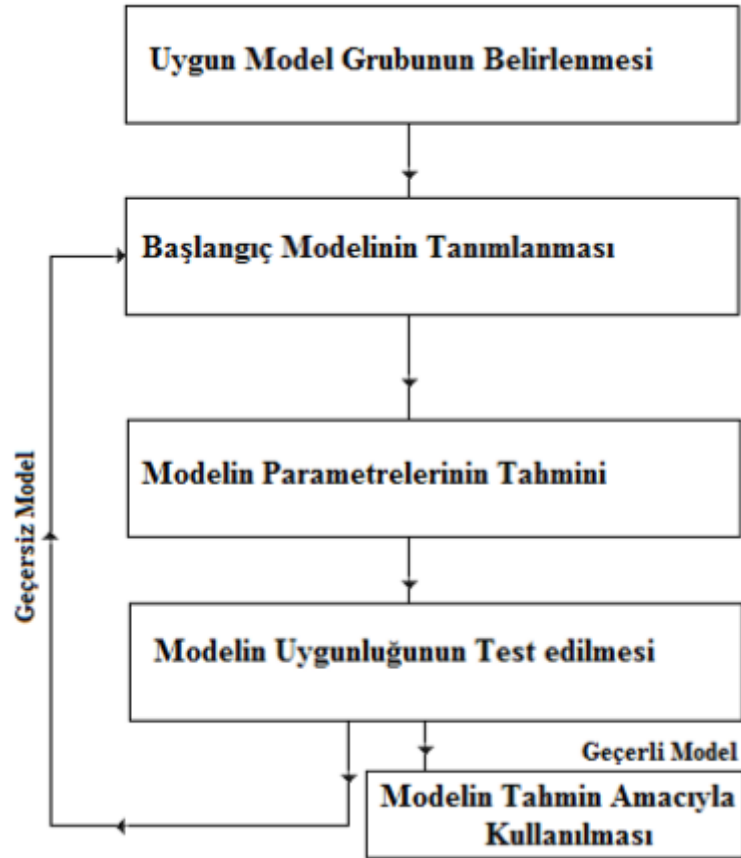
Yule tarafından ARIMA modellerinin 1921’de AR modellerinin meydana çıkartması ile kavramın ilk başlangıcı yapılmıştır. Ardından Shutsky tarafından 1927’de MA modelleri ortaya çıkarılmıştır. Daha sonar Wold tarafından 1954’de AR ve MA’nın karışımı olan ARMA modelleri kullanılmıştır. Bir süre sonar da Box ve Jenkins tarafından 1970-1976 yıllarında ARIMA modellerinin gelişmesini sağlamıştır (Çevik, 1999, s. 39).

Box-Jenkins tahmin yöntemine göre zaman serileri durağan ve durağan olmayan zaman serileri olarak iki farklı seri türünde gözlemlenmektedir. Zaman faktörü ile etkilenen durumların gelişigüzel kişilikte olması ve serinin stokastik(olasılıklı) olduğu hipotezine güvenerek Box-Jenkins tahmin modellerinin oluşturulması sağlanmıştır. Bu ifadeye ek olarak, zaman faktörünün dahilinde rasgele değişkenin gelişigüzel aldığı değerler arasında Box-Jenkins tahmin modellerinde var olan otokorelasyon göz önünde tutulur. Box-Jenkins grubu modellerine bu sebepten dolayı stokastik(olasılıklı) modeller ismi kullanılmaktadır (Güneş, 2010, s. 16).

Box-Jenkins tahmin modelleri tutumluluk temeline dayalıdır. Zaman serisine en orantılı ve minimum parametreyi içinde bulunduran doğrusal modeli bulmak, Box-Jenkins tahmin modelinin gayesidir. Zaman serisi değişkenlerinin niteliklerini açıklayan optimum başka bir değişle az sayıya parametre bulunduran veya serbestlik derecesini hesaba katan tutumluluk ilkesi, tanımlanan şekilde model oluşturmayı hedefler (Kaya, 2019, s. 36).

Gözlemlenecek olan zaman serilerinin sabit(durağan) olması, Box-jenkins tahmin modellerinde modeli oluşturmak için gerekli olan bir undurdur. Zaman serisi durağan bir şekilde büyüme, trend yapıyorsa veya bir düzeyden başka bir düzeye tekrar deri geliyorsa ya da devam ediyorsa, bahsedilen bu zaman serisi sabit(durağan) zaman serisine çevrilmeden model kurulamaz. Zaman serisi istatiksel olarak ortalama ve varyans gibi

özellikler zaman içinde sabit kalırsa, seri sabit(durağan) bir zaman serisidir (Biçen, 2006, s. 12). Box-jenkins tahmin metoduyla deterministik ve stokastik(olasılıklı), trend ve mevsimsellik unsurlarından ayırım yapılmaksızın yeterli ölçüde fark alma yöntemi gerçekleştirilir (Güneş, 2010, s. 28).



Şekil 3.6. Model Kurma Süçlerinin Basamakları (Bozdağ, 2011, s. 25)

Box-Jenkins model tanımlama basamağında seriye ait ACF(otokorelasyon), PACF(kısmi otokorelasyon) işlevlerine göz atılır. $AR(p)$, $MA(q)$, $ARMA(p,q)$, $ARIMA(p,d,q)$ modellerde otokorelasyon ve kısmi otokorelasyon işlevleri zaman serisinin hangisine ait olduğunun teşhis edilmesinde önemlidir (Biçen, 2006, s. 14).

Tablo 3.1. Otokorelasyon(ACF) ve Kısmi otokorelasyon(PACF)'nın Teorik Davranışları (Akıncı, 2008, s. 41)

Model	Otokorelasyon	Kısmi otokorelasyon
AR(p)	Azalarak kaybolur.	p gecikme sonrası kesilir.
MA(q)	q gecikme sonrası kesilir.	Azalarak kaybolur.
ARMA(p,q)	Azalarak kaybolur ve q gecikme sonrası kesilir.	Azalarak kaybolur ve p gecikme sonrası kesilir.

3.1.1. Doğrusal Durağan Stokastik Modeller

Box-Jenkins tahmin modelinde doğrusal durağan stokastik modeller:

- AR(Otoregresif Model),
- MA(Hareketli Ortalama Modeli),
- ARMA (Otoregresif Hareketli Ortalama Modeli) olmak üzere tanımlanmıştır (Duru, 2007, s. 16).

Otoregresif Model (AR): “AR modelde sürecin şimdiki değeri, sürecin geçmiş değerinin doğrusal toplamı ve hata terimi gibi rassal şoktan oluşan sınırlı değerlerdir (Akdağ, 2015, s. 25).”

“Otoregresif modelde bulunan AR (p) modelin genel ifadesi:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \phi_3 Y_{t-3} + \dots + \phi_p Y_{t-p} + e_t$$

$$t = 1, 2, 3, \dots, T$$

ϕ : Otoregresif parametrelerini,

δ : Sürecin ortalaması ile ilgili olan sabit terim,

p: Modelin derecesini,

e_t : Normal dağılmış bir hata terimini,

Y_t : Gözlem değerini tanımlar ve modelde tanımlanan ifadeler denklemde yerine konulur ise,

$$\text{AR (1) } Y_t = \delta + \phi_1 Y_{t-1} + e_t,$$

$$\text{AR (2) } Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + e_t \text{ denklem karşımıza çıkar (Kaya, 2019, s. 41) .”}$$

Hareketli Ortalama Modeli (MA): İncelenen zaman serisinde gecikmeli hata değeri var olan periyotlarda hata değerini etkisi altına alıyor ise hareketli ortalama modeli olarak tanımlanır ve bu modelde değişkenlerin hata değeri ile tahmin değeri ise birbirleriyle ilişkilidir (Akdağ, 2015, s. 25).

Uzun dönemli verilerin zaman serilerinde var olması hareketli ortalama modeli (MA) uygulanabileceği anlamını taşır (Şenyüz, 2019, s. 25).

“Hareketli ortalama modeli MA (q) aşağıdaki gibi ifade edilir :

$$Y_t = \mu + e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2} + \theta_3 e_{t-3} + \dots + \theta_q e_{t-q}$$

μ : Sabit terimdir,

e_t : Sıfır ortalamaya ve sabit bir varyansa sahip olan hata terimidir,

θ_i (i:1,2,...,q): Bilinmeyen parametrelerini tanımlar ve modelde tanımlanan ifadeler yerlerine konulur ise,

$$\text{MA (1) } Y_t = \mu + e_t + \theta_1 e_{t-1} ,$$

$$\text{MA (2) } Y_t = \mu + e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2} \text{ denklemi karşımıza çıkar (Kaya, 2019, s. 45, s. 46).”}$$

Otoregresif Hareketli Ortalama Modeli (ARMA): Box-Jenkins tahmin modelinde esneklik uygulamak ve minimum sayıda parameter barındırma prensibini ortaya koymak amacıyla bazı durumlarda hareketli ortalama modeli aynı zamanda otoregresif parametrelere sahip olmak bir hayli yararlı olmaktadır. Box-Jenkins tahmin modellerinde ARMA (p,q) bu fikir ile meydana gelmiştir (Akdağ, 2015, s. 26).

Genel bir ARMA (p,q) modeli ise:

$$Y_t = \delta + \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + e_t + \theta_1 e_{t-1} + \dots + \theta_q e_{t-q}$$

Yukarıda ifadedeki gibi gösterilir (Yoloğlu, 2020, s. 29).

3.1.2. Doğrusal Durağan Olmayan Stokastik Modeller (ARIMA)

Durağan zaman serilerinde ileriye yönelik bir tahmin yapabilmek için AR(Otoregresif), MA(Hareketli ortalama) ve ARMA(Otoregresif hareketli ortalama) Box-Jenkins tahmin modelleri kullanılırken, ARIMA Box-Jenkins tahmin modeli ise durağan olmayan zaman serilerinin durağanlığı için yeterli sayıya fark alma yöntemini yaparak gerçekleştirmektedir (Ersen, 2016, s. 35).

Hareketli ortalama parametre derecesi q , otoregresif parametresi p ve d defa fark alma metodu gerçekleştirilmiş ise, ARIMA(p,d,q) biçiminde ifade edilir ve (p,d,q) dereceden otoregresif entegre hareketli ortalama modeli olarak anılmaktadır (Duru, 2007, s. 21).

ARIMA(otoregresif entegre hareketli ortalama) modeli:

$$wt = \phi_1 wt-1 + \phi_2 wt-2 + \dots + \phi_p wt-p + et - \theta_1 et-1 - \theta_2 et-2 - \dots - \theta_q et-q$$

Biciminde ifade edilir. İfadede ise wt farkı alınmış seriyi temsil eder (Akşit, 2019, s. 38).

3.1.3. Box-Jenkins Tahmin Yönteminin Üstün Ve Zayıf Yönleri

Box-Jenkins tahmin yönteminin üstün yönleri aşağıdaki gibi bahsedilebilir:

-Box-Jenkins tahmin modeli kurulan modelin her basamağında tahmin için analiz edilirken zaman serisine elverişli olup olmadığı ile ilgili sorgulama fırsatı sunmaktadır (Kaya, 2019, s. 52).

-Model doğru yapıldığında en uygun tahminleri veren Box-Jenkins tahmin modellerinin birden fazla miktarda modelleri içinde barındırması araştırmaya yapan kişi için modellerden optimum olanı bulma ve seçme hakkı sunar (Polat, 2009, s. 61).

Box-Jenkins tahmin yönteminin zayıf yönleri aşağıdaki gibi bahsedilebilir:

-Optimum tahmin sonuçlarının Box-Jenkins tahmin yöntemi ile sonuca varılması araştırma yapan kişinin yeterli bilgiye ve deneyimli olması lazımkken, Box-Jenkins tahmin modellerinin fazla miktarda modellerinin içinde barındırmasından dolayı araştırmacı kendine optimum sonucu vermeyen bir model ile çalışabilir (Kaya, 2019, s. 52).

-Optimum modelin tanımlanması sürecin uzun sürmesinden, diğer tahmin yöntemlerine göre daha çok vakit harcamaktadır (Polat, 2009, s. 62).

3.2. Üstel Düzgünleştirme Yöntemi

Üstel düzgünleştirme(düzeltilme) tahmin yöntemlerinde geçmiş dönemlerdeki verilere ağırlık verilme mantığıyla çalışır. Geçmiş dönemdeki verilerden yakın olanlara daha fazla ağırlık verilir, uzakta olan verilere ise daha düşük ağırlık verilir. Bunun sebebi zaman serisindeki son dönemde verilerin geleceğin tahminine daha çok ettiği düşünülür. Bu özelliğiyle de basit hareketli ortalamalar yönteminden ayrılmaktadır (Çuhadar, 2006, s. 78,79).

3.2.1. Basit Üstel Düzgünleştirme Yöntemi

Bu yöntem literatür araştırmasında Brown'un basit üstel düzeltmesi olarak da bilinmektedir. Zaman serisindeki verilerin mevsimsellik, trend faktörünün olmadığı ve serisinde durağan olduğu varsayılarak tahminlenme işlemi yapar (Demirbaş, 2011, s. 19).

Basit üstel düzgünleştirme yöntemi ağırlıklı hareketli ortalamalar yönteminin biraz daha özelleşmiş halidir. Burada $\alpha \in [0,1]$ düzgünleştirme katsayısı olsun. Basit üstel düzgünleştirme yönteminde zaman serisindeki en eski veriye en düşük ağırlığı, en yeni veriye en yüksek ağırlık verilmektedir. $\sum_{i=1}^n a_i = 1$ olacak şekilde düzgünleştirme katsayısının yardımıyla toplam değeri bir olacak şekilde işlem sağlanır. Toplam

işleminin sonucu olarak $t+1$.periyodun ihtiyaç miktarı tahmin edilirken; t .periyottaki talep ve tahmin değerleri arasındaki farkı, düzgünleştirme katsayısını da işin içine katarak bir düzeltme yapılır (Aydemir, 2013, s. 54).

α 'yı ($0 < \alpha < 1$) düzgünleştirme katsayısı ve geçmişteki t dönem içinde zaman serilerinin Y_1, Y_2, Y_3, \dots olarak gösterelim. Sonraki $t+1$ dönemin tahmini F_{t+1} 'in matematiksel olarak karşılığı şöyledir.

$$F_{t+1} = \alpha Y_t + \alpha(1-\alpha)Y_{t-1} + \alpha(1-\alpha)^2 Y_{t-2} + \dots$$

Formulde olduğu gibi $Y_t, Y_{t-1}, Y_{t-2}, \dots$ 'nin katsayıları azalmaktadır. Böylelik yeni olan verilere daha fazla ağırlık verilmektedir. F_{t+1} 'i hesaplayan eşitlik aşağıda basitleştirilerek gösterilmiştir.

$$F_{t+1} = \alpha Y_t + (1-\alpha) \{ Y_{t-1} + \alpha(1-\alpha)Y_{t-2} + \alpha(1-\alpha)^2 Y_{t-3} + \dots \}$$

$$F_{t+1} = \alpha Y_t + \alpha(1-\alpha)F_t$$

F_{t+1} değerleri yinelenerek F_t değerinden hesaplanabilir. $t=1$ olduğu durumda F_1 'in tahmini tahmini atlanarak başlatılır. $t=2$ 'nin tahminlemesi ise $t=1$ 'de gerçek veriye eşit olur. Böylelikle $F_2 = Y_1$ yazılır.

$$F_{t+1} = F_t + \alpha(Y_t - F_t) \quad (3.10)$$

F_{t+1} = $t+1$ dönemi için tahmin değeri

Y_t = t döneminde gerçekleşen değer

F_t = t dönemi için tahmin değeri

α = düzgünleştirme katsayısı ($0 < \alpha < 1$)

$Y_t - F_t$ ifadesi, önceki dönemlere ait tahmini hata değeridir. Eğer bu değer pozitifse gerçekleşen değer tahmin edilenden büyüktür ve uygulanacak olan düzgünleştirme tahmin değerini artırtma yönünde devam edecektir. Eğer negatif olursa tahmin değeri

gerçekleşenden değerden fazla olduğu kabul edilir ve sonrasında uygulanacak olan düzgünleştirme tahmininde azaltma yönünde devam edecektir (Demirbaş, 2011, s. 20).

3.2.2. Holt'un İki Parametrelili Doğrusal Üstel Düzgünleştirme Yöntemi (Holt Trend Metot)

Holt'un (1957), trend faktörünün olduğu verilerde tahmin yapabilmek için basit üstel düzgünleştirmeyi geliştirmiştir. Bu yöntem de, bir tahmin denklemi ve 2 tane düzgünleştirme denklemleri vardır. Düzgünleştirme denklemlerinin birinde seviye değerinde ise trend düzgünleştirmesi vardır (Şener, 2019, s. 36).

Bu yöntemde kullanılan 0 ile 1 arasında değerleri olan α ve γ gibi düzeltme katsayılarından, üç tane denklemden oluşur. İlk denklemde, Y'_t , t anında düzeltilmiş halinin değerini, b_t ise t anında serinin tahmin eğimini belirtir. İlk denklemde, geçmiş döneme ait eğilim b_{t-1} son düzeltilmiş değer olan Y'_{t-1} 'e eklenir. Bu işlemle birlikte gecikme engellemektedir ve Y'_t değerini cari gözlem değerine yakınlaştırır. İkinci denklemde, trend güncellenerek, düzgünleştirilmiş olan son iki değer arasında çıkarma işlemi yapılarak farkı alınır. Bu model için kabul gören bir yaklaşımdır. Çünkü verilerde trend var ise tahmin edilen değerler eski değerlere göre düşük veya yüksek olabilir. $Y'_t - Y'_{t-1}$ değeri, γ ile güncellenebilmektedir ve $(1 - \gamma)$ ile çarpılmış olup eski tahmin trendine eklenecektir. Geriye kalan en son denklemimiz ise tahminlemek için kullanılmaktadır. Tren faktörü, kaç adımlama (h) tahmin edilecek ise h ile çarpılır ve düzgünleştirilmiş değerler ile toplanmaktadır (Can, 2009, s. 76).

$$Y'_t = \alpha Y_t + (1 - \alpha)(Y'_{t-1} + b_{t-1}) \text{ (Üstel Düzgünleştirme)}$$

$$b_t = \gamma(Y'_t - Y'_{t-1}) + (1 - \gamma)b_{t-1} \text{ (Trend Faktörü)}$$

$$\hat{Y}_{t+m} = Y'_t + b_t m \text{ (tahmin denklemi)}$$

α ve γ için hata karelerini düzgünleştirme katsayılarının toplamını en az yapacak olan değerleri 0 ile 1 arasındaki tüm reel sayıların deneme yanılma yoluyla bulunması gerekmektedir. Eğer α değeri 1'e yakın ise cari değerlere, 0'a yakın ise geçmiş değerlere ağırlık vermektedir. γ 'nin sıfıra yakın olması ise trendin geçmiş zamanlarındaki değerler

önem kazanmaktadır, eğer sıfır ise trend sabittir ve tüm değerler için tahminler sabit kalır ve “bire yakın olması durumunda düzgünleştirilmiş değerler arasındaki değişimler ($Y'_t - Y'_{t-1}$) daha önemli hale gelir (Akgül, 2003, s. 126)” (Akgül, 2003, s. 126). α ve γ eğer birbirlerine eşit ise basit üstel düzgünleştirme yöntemi olmaktadır (Can, 2009, s. 77).

Holt'un trend yöntemiyle tahmin yapmak istiyorsak giriş olarak iki tane değere ihtiyacımız vardır. Bunlar, ilk temel değer ve ilk trend değeridir. Bu değerlere, ilk gözlemi Y_1 temel değere ve ilk trendi, ikinci ve ilk gözlemin farkıyla ($Y_2 - Y_1$) veya birden fazla gözlemin ortalamasına eşitleyerek ulaşılabilir (Demirbaş, 2011, s. 22).

Yavaşlayan (Damped)Trend, üstel düzgünleştirmede trend faktörünün varlığını kabul edip doğrusal olması durumunda ek bir yöntem olarak önerilen metoddur. Yavaşlayan trend, zaman serilerinin uzun dönemde ortaya çıkardıkları trend eğilimin etkisinin giderek azalırken ortaya çıkan trendini belirtmek için kullanılır (Akgül, 2003, s. 131).

Yavaşlayan trend yöntemi uygulanırken zaman serisinin mevsimsellik etkisine de bakılır (Can, 2009, s. 79).

π =yavaşlama katsayısı, $0 < \pi < 1$ olarak etki göstermektedir.

Serinin genel düzgünleştirilmesi için kullanılan denklem;

$$Y'_t = \alpha Y_t + (1-\alpha)(Y'_{t-1} + \pi b_{t-1})$$

Bu yöntemde trendin düzgünleştirilmesi gerçekleştirilir. Bunun için kullanılan denklem;

$$b_t = \gamma(Y'_t - Y'_{t-1}) + (1-\gamma)\pi b_{t-1}$$

İlk gözlemin düzgünleştirilmiş tahmin değeri ise b_0 'dır.(ilk dönem trendi)

$$b_0 = \frac{1}{\pi} \frac{\gamma n - \gamma - 1}{n - 1}$$

$Y_0 = \frac{y_1 - b_0}{2}$ formülüyle elde edilir.

Y_1 ; ilk gözlem değerini,

Y_n ; son gözlem değerini

n ; gözlem sayısını

Yöntemin tahmin denklemi ise,

$Y_{t+m} = Y_t + \sum_{i=1}^m \pi^i b_t$ 'dir (Can, 2009, s. 79).

3.2.3. Üstel Düzeltme Yöntemin Avantajları ve Dezavantajları

Üstel düzgünleştirme yönteminin avantajları olarak düşük maliyetli olması ve uygulamasının basit olması belirtilebilir. Bununla beraber, diğer özelliği de zaman serilerin eklenicek olan verilerin de tahminleme modelinin içine katması ve yeni dönem tahminlerinde etkisini gösterebilmesidir (Demirbaş, 2011, s. 19).


Üstel düzgünleştirme yönteminin bazı dezavantajlı olduğu kısımlarda vardır. Bunlar, üstel düzeltme yöntemlerinde kullanılan α ve γ katsayılarının uygun bir şekilde en iyi sonucu veren değerini bulmak için yapılacak bir testin ve kuralın olmamasıdır. Bu durum deneme yanılma yöntemleriyle çözülmeye çalışılır. Bir diğeri ise kullanılan üstel düzeltme yöntemlerinde kullandığımız modellerin bu yöntem için yeterli mi yoksa yeterli değil mi sorusunun cevabını alabilmemiz için herhangi bir testin bulunmamasıdır. Bu durumda da deneme yanılma yöntemi kullanılır. Bu vakit anlamında uğraştıran bir süreçtir (Çevik, 1999, s. 33,34).

3.3. Yinelenen Sinir Ağları(Rnn)

Yinelenen sinir ağları yapay sinir ağlarında en başarılı ağ mimarilerinden biridir. Genellikle sıralı verileri işlerken derin öğrenme alanında kullanılır. Tekrarlayan bir sinir ağı aynı ağ içerisine birbirlerine mesaj yollayan bir kopya ağ olarak düşünülebilir (S. Hochreiter ve J. Schmidhuber, 1997).

RNN bir çeşit CNN mimarisini kullanan bir ileri besleme mimarisidir. Bu yapıda, giriş verileri ağdan geçirilir ve bir çıkış verisi alınır. Denetimli öğrenme ile çıktı üzerinde bir etiketleme yapılır. Veriler Şekil 3.7'de olduğu gibi kategorilere ayrılır. İleri besleme ağları


girdilerini sınıflandırma hatası minimum düzeye inene kadar eğitim yapar. Böylece nöronlara yol açan ağırlıklar verilen girdiyi kategorize edilebilecek bir şekilde yenilenir. Önceki veya sonraki verilerle arasında bir bağlantıya gerek yoktur. Zamana bağlı bir kavram yoktur ilgilendiği tek girdi mevcut veridir (Brownlee, 2017) .



Şekil 3.7. Sinir Ağlarının Kategorilere Ayrılması (Sinir Ağları, 2017)

Bir zincir benzeri yapıya sahip olan RNN’lerde dizi ve liste veri yapıları ile yakından ilişkili olduğunu gösterir. Bunlar benzer verilerin kullanımı için sinir ağlarının doğal bir mimarisidir. RNN’ler konuşma tanımlama, dil modelleme, tahmin yapma, çeviri gibi birçok uygulamada başarılı sonuçlar vermişlerdir (Chung ve diğerleri, 2015).

Diğer ileri beslemeli sinir ağlarında girdiler birbirinden bağımsız olarak ele alınır ve girdilerin ağı geliş sırasının bir önemi yoktur. Girdiler ağıdaki işlemi bittikten sonra sinir bu girdiyi unuttur (Alam, 2018). Diğer sinir ağlarında bir tahmin yapabilmek için eski verilerin bilgisine ihtiyaç vardır. RNN’ler ise hafızalı sinir ağları olarak üretilmişlerdir. Ağda eğitim yapılırken bir önceki verinin bilgilerini hafızasında tutar. RNN ve diğer ileri beslemeli ağlar arasındaki fark Şekil 3.8’de verilmiştir (Bengio, Simard ve Franscon, 2015).



Şekil 3.8. RNN ve Diğer İleri Beslemeli Ağlar (Recurrent Neural Networks And Lstm, 2018)

3.3.1. Rnn Avantaj ve Dezavantajları

“Avantajları, geçmiş verilerin dikkate alınarak hesaplanabilmesi, girdi büyüklüğüne bağlı olarak artmayan model boyutu, herhangi bir girdiyi işleme yeteneği, zaman içinde paylaşılan ağırlıklar olarak sıralanabilir. Dezavantajları, yavaş hesaplama, uzun zaman geçmiş verilere ulaşma zorluğu, mevcut durum için gelecekteki herhangi bir girdinin düşünülmemesidir. (Gers, 2001).”


RNN’ler uzak geçmişi hatırlamakta zorluk çekerler. Bu sorunun çözümü olarak LSTM geliştirilmiştir. LSTM degrade kaybolma sorununu çözebilmektedir. Bu sebeple tahmin yapmak için genellikle LSTM tercih edilmektedir (Bengio, Simard ve Franscon, 2015).

3.3.2. Gradyan Kaybolma Sorunu

Gradyan tüm ağırlıkları ayarlamamızı sağlayan bir değerdir. Uzun bağlı ağlarda hatanın etkisi azalmaya başlar ve degrade kaybolmaya başlayabilir. Bu durum ise doğru sonucu bulmayı zorlaştırmaktadır. Bu sorunun önüne ise LSTM ile geçilebilmektedir (Bengio, Simard ve Franscon, 2015).

3.3.3. Lstm

LSTM, RNN’in uzun zaman önceki verileri öğrenebilen özel bir çeşididir. 1997 yılında Hochreiter ve Schmidhuber tarafından tanıtılmıştır Şekil3.9’da ilk LSTM mimarisi verilmiştir (S. Hochreiter ve J. Schmidhuber, 1997).



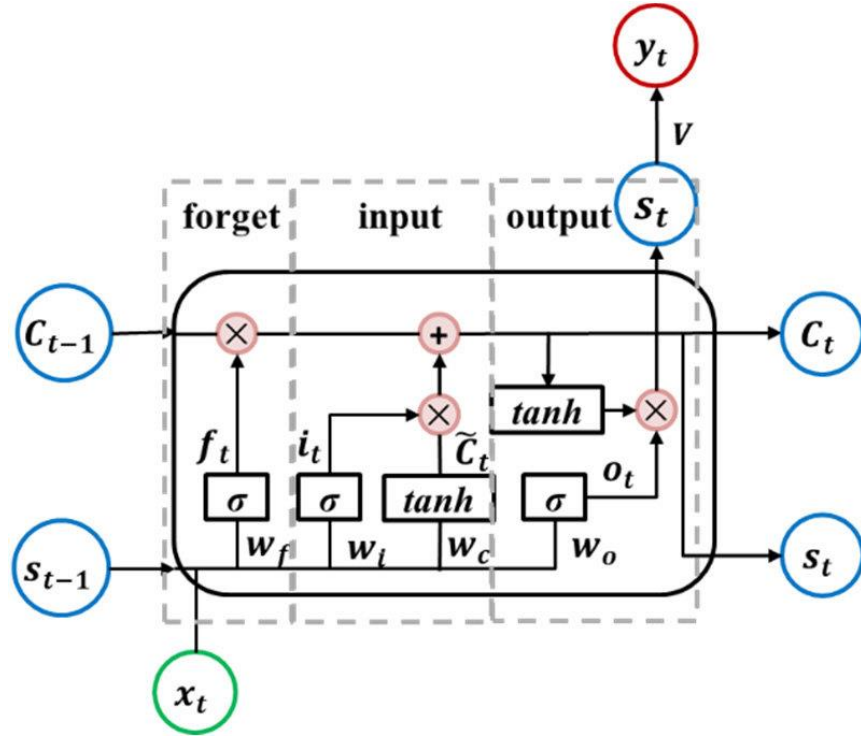
Şekil 3.9. İlk LSTM Mimarisi (Recurrent Neural Networks - 02 Long Short-Term Memory, 2017)

LSTM, yinelenen ağ mimarisine sahip bir makine öğrenme algoritmasıdır. Model olarak kısa periyotta öğrenilen bilgiyi depolamaktadır ve bunu uzun periyotta öğrenim için kullanmaktadır. Tekrarlayan sinir ağlarında, son verinin tahmini için kullanılan eğitim verisinde fazla miktarda gereksiz veri bulunursa, ilk verilerin analiz edilmesiyle son verinin doğru tahmin edilme ihtimali düşmektedir (S. Hochreiter ve J. Schmidhuber, 1997).

Bir LSTM yapısı RNN hücresinin hafızayla birlikte çalışması durumudur. Bu hafıza ile geçmiş zaman verileri alınır ve gelecek zamana iletilir. Hangi bilginin değerlendirilip değerlendirilmeyeceğine eğitim ile karar verilir. RNN çalışmalarında tahmin yapabilmek için LSTM kullanılmaktadır (Klaus, 2016). Literatürde kullanılan çok fazla LSTM varyasyonu vardır. Bunlardan en çok kullanılanı GRU'dur. Bu projede de LSTM ve GRU kullanılmıştır.

3.3.4. Gru

GRU, 2014 yılında Cho ve arkadaşları tarafından tanıtılmıştır (Cho ve diğerleri, 2014). GRU bir LSTM ağının varyasyonudur. LSTM ile aynı metodu izler fakat LSTM'den farklı olarak bu modeldeki kapı sayısı ikidir. Tıpkı LSTM gibi tekrarlayan bir sinir ağını gradyan kaybolma sorunundan korur. Bazı durumlarda LSTM'ye benzer sonuçlar verdiği için LSTM hücresinin basitleştirilmiş bir versiyonudur. Şekil3.10'da GRU mimari yapısı verilmiştir.




Şekil 3.10. GRU Mimari Yapısı (Simple RNN vs GRU vs LSTM, 2018)

BÖLÜM 4. BULGULAR VE DEĞERLENDİRME

Bu araştırmada Box-Jenkins tahmin modelleri, üstel düzeltme tahmin yöntemi ve yapay sinir ağları kullanılarak ileriye yönelik dolar kuru tahmininde bulunulmuştur. Daha sonra ise modellerin mukayesesi yapılmıştır. Araştırma gerçekleştirilirken ele alınan veri seti olarak haftalık Türkiye Cumhuriyeti Merkez Bankası dolar kuru verileri temel olarak alınmıştır.

Tablo 4.2. 2005-2020 Yılları Arasındaki Haftalık Türkiye Cumhuriyet Merkez Bankası Dolar Kurları Verileri (TCMB, 2020)

Tarih	Dolar Kuru
07/01/2005	1,358960
14/01/2005	1,370280
21/01/2005	1,339233
...	...
21/02/2020	6.056080
28/02/2020	6.133600
06/03/2020	6.161400
13/03/2020	6.136720
20/03/2020	6.410660
27/03/2020	6.484600
03/04/2020	6.566040
10/04/2020	6.738280
17/04/2020	6.796500
24/04/2020	6.937825



Şekil 4.11. 2005-2020 Yılları Arasında Haftalık Türkiye Cumhuriyet Merkez Bankası Dolar Kurları Verilerinin Zamana Göre Değişimi Grafiği

4.1. Box-Jenkins Tahmin Yöntemi

Box-Jenkins tahmin yönteminde verilerin istatistiksel açıdan anlamlı sonuçlara ulaşabilmesi gerektiğinden elde edilmiş zaman serilerinin durağan (sabit) olması lazımdır. Zaman serisinin PACF (kısmi otokorelasyon) ve ACF (otokorelasyon) yola çıkarak zaman serisinin durağanlığını anlayabiliriz (Akdağ, 2015, s. 43).

Kısmi otokorelasyon ve otokorelasyon fonksiyonlarına bakılarak durağanlığını test etme işlevlerine ilave olarak birim kök testlerinden de yardım alınabilir. Kısmi otokorelasyon ve otokorelasyon fonksiyonunun testinden elde edilen bulgulara göre p ve q değerleri karşılaştırılabilir. $AR(p)$ modelinde otokorelasyon fonksiyonu p gecikmeleri olan çıkmalar gösterir aynı zamanda otokorelasyon üstel olarak azalır. $MA(q)$ modelinde otokorelasyon fonksiyonu q gecikmeleri olan çıkmalar gösterir aynı zamanda kısmi otokorelasyon fonksiyonu üstel olarak azalır. $ARMA(p,q)$ modelinde ise kısmi otokorelasyon ve otokorelasyon fonksiyonu aynı anda üstel olarak azalır (Akdağ, 2015, s. 43).

Bu projede, Box-Jenkins tahmin modelinde yukarıda da bahsedildiği gibi model belirlemede ilk koşul veri setinin durağanlığını kontrol etmektir. Bu aşamadan yola çıkarak ACF(otokorelasyon) ve PACF(kısmi otokorelasyon) grafiklerine göz atılır.

Autocorrelation	Partial Correlation		AC	PAC	Q-Stat	Prob
		1	0.992	0.992	789.91	0.000
		2	0.985	-0.006	1568.7	0.000
		3	0.977	0.008	2336.8	0.000
		4	0.970	-0.023	3093.8	0.000
		5	0.962	0.016	3840.2	0.000
		6	0.955	0.006	4576.2	0.000
		7	0.948	0.013	5302.4	0.000
		8	0.942	0.053	6020.1	0.000
		9	0.935	-0.024	6728.8	0.000
		10	0.929	0.023	7429.3	0.000
		11	0.923	0.013	8121.8	0.000
		12	0.918	0.018	8806.9	0.000
		13	0.912	0.007	9484.9	0.000
		14	0.907	0.002	10156.	0.000
		15	0.902	0.002	10819.	0.000
		16	0.897	0.008	11476.	0.000
		17	0.891	-0.015	12126.	0.000
		18	0.886	-0.007	12769.	0.000
		19	0.880	-0.007	13404.	0.000
		20	0.875	0.019	14033.	0.000
		21	0.870	0.012	14655.	0.000
		22	0.865	0.004	15271.	0.000
		23	0.860	0.000	15880.	0.000
		24	0.855	0.004	16483.	0.000
		25	0.850	0.010	17080.	0.000
		26	0.845	0.001	17672.	0.000
		27	0.840	-0.009	18258.	0.000
		28	0.835	-0.019	18837.	0.000
		29	0.831	0.018	19410.	0.000
		30	0.826	0.022	19978.	0.000
		31	0.822	-0.007	20541.	0.000
		32	0.817	-0.003	21098.	0.000
		33	0.812	-0.011	21649.	0.000
		34	0.808	-0.011	22195.	0.000
		35	0.802	-0.019	22734.	0.000
		36	0.798	0.021	23268.	0.000

Şekil 4.12. Türkiye Cumhuriyeti Merkez Bankası Dolar Kuru Verilerinin Korelogramı

Dolar kuru veri setinin korelogram grafiğinde Şekil 4.12.'de göz atıldığında ACF(otokorelasyon) çok yüksek bir değerden başlayarak az bir şekilde azalmaya gittiğinden serinin durağan(sabit) olmadığını sonuca bakılarak görülebilir.

Null Hypothesis: DOLAR_KURU has a unit root
Exogenous: Constant
Lag Length: 11 (Automatic - based on SIC, maxlag=20)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	2.751796	1.0000
Test critical values: 1% level	-3.438433	
5% level	-2.864998	
10% level	-2.568666	

*Mackinnon (1996) one-sided p-values.

Şekil 4.13. Dolar Kuru Verilerinin Sabit Terimli ADF Birim Kök Test Sonucu

Null Hypothesis: DOLAR_KURU has a unit root
Exogenous: Constant, Linear Trend
Lag Length: 11 (Automatic - based on SIC, maxlag=20)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	0.309390	0.9987
Test critical values: 1% level	-3.969755	
5% level	-3.415536	
10% level	-3.130002	

*Mackinnon (1996) one-sided p-values.

Şekil 4.14. Dolar Kuru Verilerinin Sabit Terimli ve Trendli ADF Birim Kök Testi Sonucu


Null Hypothesis: DOLAR_KURU has a unit root
Exogenous: None
Lag Length: 11 (Automatic - based on SIC, maxlag=20)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	3.738089	1.0000
Test critical values: 1% level	-2.567904	
5% level	-1.941226	
10% level	-1.616429	

*Mackinnon (1996) one-sided p-values.

Şekil 4.15. Dolar Kuru Verilerinin Sabit Terimsiz ADF Birim Kök Test Sonucu

Hesaplanan ADF test istatistiğinin değeri kritik değerlerden küçük ise (negatif olarak) sıfır hipotezi ($H_0: \rho \geq 1$ ise seri durağan değildir.) reddedilir yani birim kök yoktur seri durağandır ve seri $H_1: \rho < 1$ ise seri durağandır bilgilerinden yola çıkılarak, dolar kuru verilerinin Şekil 4.13, Şekil 4.14 ve Şekil 4.15 'de ADF testinde durağan olmadığı anlaşılır. Durağanlaştırmak için serinin logaritması alınır.



Şekil 4.16. Logaritması Alınmış Dolar Kuru Verilerinin Zamana Göre Dağılımı

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
		1	0.995	0.995	794.40	0.000
		2	0.990	-0.020	1581.9	0.000
		3	0.985	-0.001	2362.7	0.000
		4	0.980	-0.018	3136.4	0.000
		5	0.975	0.006	3903.3	0.000
		6	0.970	-0.001	4663.3	0.000
		7	0.966	0.002	5416.6	0.000
		8	0.961	0.031	6163.7	0.000
		9	0.956	-0.017	6904.4	0.000
		10	0.952	0.007	7638.9	0.000
		11	0.947	0.014	8367.4	0.000
		12	0.943	0.020	9090.4	0.000
		13	0.939	0.005	9807.8	0.000
		14	0.934	-0.010	10520.	0.000
		15	0.930	-0.006	11226.	0.000
		16	0.926	0.010	11927.	0.000
		17	0.922	-0.011	12622.	0.000
		18	0.917	-0.006	13312.	0.000
		19	0.913	-0.004	13996.	0.000
		20	0.909	0.008	14674.	0.000
		21	0.905	0.005	15347.	0.000
		22	0.901	0.004	16015.	0.000
		23	0.896	-0.003	16678.	0.000
		24	0.892	0.003	17336.	0.000
		25	0.888	0.007	17988.	0.000
		26	0.884	-0.004	18636.	0.000
		27	0.880	-0.012	19278.	0.000
		28	0.876	-0.016	19915.	0.000
		29	0.872	0.006	20547.	0.000
		30	0.868	0.013	21174.	0.000
		31	0.864	-0.008	21796.	0.000
		32	0.860	-0.003	22412.	0.000
		33	0.856	-0.003	23024.	0.000
		34	0.851	-0.009	23631.	0.000
		35	0.847	-0.015	24232.	0.000
		36	0.843	0.010	24828.	0.000

Şekil 4.17. Logaritması Alınmış Dolar Kuru Verilerinin Korelogramı

Logaritması alınmış dolar kuru veri setinin korelogram grafiğinde Şekil 4.17’de göz atıldığında ACF(otokorelasyon) çok yüksek bir değerden başlayarak az bir şekilde azalmaya gittiğinden serinin durağan (sabit) olmadığı sonucu görülebilir.

Null Hypothesis: LOGDK has a unit root
 Exogenous: Constant
 Lag Length: 3 (Automatic - based on SIC, maxlag=20)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	1.074513	0.9973
Test critical values: 1% level	-3.438350	
5% level	-2.864961	
10% level	-2.568646	

*MacKinnon (1996) one-sided p-values.

Şekil 4.18. Logaritması Alınmış Dolar Kuru Verilerinin Sabit Terimli ADF Birim Kök Testi Sonucu

Null Hypothesis: LOGDK has a unit root
 Exogenous: Constant, Linear Trend
 Lag Length: 3 (Automatic - based on SIC, maxlag=20)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-1.667932	0.7646
Test critical values: 1% level	-3.969636	
5% level	-3.415478	
10% level	-3.129968	

*MacKinnon (1996) one-sided p-values.

Şekil 4.19. Logaritması Alınmış Dolar Kuru Verilerinin Sabit Terimli ve Trendli ADF Birim Kök Testi Sonucu


Null Hypothesis: LOGDK has a unit root
 Exogenous: None
 Lag Length: 3 (Automatic - based on SIC, maxlag=20)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	2.621387	0.9981
Test critical values: 1% level	-2.567874	
5% level	-1.941222	
10% level	-1.616431	

*MacKinnon (1996) one-sided p-values.

Şekil 4.20. Logaritması Alınmış Dolar Kuru Verilerinin Sabit Terimsiz ADF Birim Kök Test Sonucu

Logaritması alınmış dolar kuru very setinin hesaplanan ADF test istatistiği değeri kritik değerden küçük ise (negatif olarak) sıfır hipotezi($H_0: \rho \geq 1$ ise seri durağan değildir.) reddedilir yani birim kök yoktur seri durağandır ve seri $H_1: \rho < 1$ ise seri durağandır bilgilerinden yola çıkılarak, logaritması alınmış dolar kuru verilerinin Şekil 4.18, Şekil 4.19 ve Şekil 4.20’de ADF testinde durağan olmadığı anlaşılır. Durağanlaştırmak için logaritması alınmış veri setinin birinci dereceden farkı alınır.



Şekil 4.21. Logaritması ve Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Zamana Göre Dağılımı

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
		1	0.205	0.205	33.565	0.000
		2	0.035	-0.007	34.568	0.000
		3	0.136	0.136	49.473	0.000
		4	0.044	-0.012	51.014	0.000
		5	0.025	0.019	51.502	0.000
		6	-0.011	-0.039	51.599	0.000
		7	-0.076	-0.074	56.242	0.000
		8	0.043	0.072	57.711	0.000
		9	-0.083	-0.110	63.219	0.000
		10	-0.046	0.017	64.968	0.000
		11	-0.086	-0.103	70.974	0.000
		12	-0.004	0.066	70.988	0.000
		13	0.053	0.044	73.269	0.000
		14	0.043	0.049	74.745	0.000
		15	-0.056	-0.074	77.263	0.000
		16	-0.006	-0.012	77.296	0.000
		17	0.033	0.033	78.180	0.000
		18	0.003	-0.021	78.189	0.000
		19	-0.002	0.025	78.193	0.000
		20	-0.007	-0.036	78.229	0.000
		21	-0.042	-0.031	79.659	0.000
		22	0.008	0.006	79.714	0.000
		23	-0.062	-0.044	82.830	0.000
		24	-0.090	-0.056	89.532	0.000
		25	-0.027	-0.003	90.125	0.000
		26	0.027	0.044	90.740	0.000
		27	0.000	-0.003	90.740	0.000
		28	-0.006	0.012	90.775	0.000
		29	-0.026	-0.030	91.343	0.000
		30	0.008	-0.003	91.403	0.000
		31	-0.010	-0.024	91.488	0.000
		32	0.007	0.019	91.526	0.000
		33	0.045	0.042	93.217	0.000
		34	0.027	-0.001	93.812	0.000
		35	-0.001	-0.010	93.813	0.000
		36	-0.022	-0.041	94.210	0.000

Şekil 4.22. Logaritması ve Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Korelogramı

Logaritması ve birinci dereceden farkı alınmış dolar kuru verilerinin Şekil 4.22’de göz atıldığında ACF(otokorelasyon) azalmaya gittiği anlaşılabılır buna göre serinin durağan(sabit) olduğu görülebilir.

Null Hypothesis: DIFLOGDK has a unit root
 Exogenous: Constant
 Lag Length: 2 (Automatic - based on SIC, maxlag=20)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-13.13000	0.0000
Test critical values: 1% level	-3.438350	
5% level	-2.864961	
10% level	-2.568646	

*MacKinnon (1996) one-sided p-values.

Şekil 4.23. Logaritması ve Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Sabit Terimli ADF Birim Kök Test Sonucu

Null Hypothesis: DIFLOGDK has a unit root
 Exogenous: Constant, Linear Trend
 Lag Length: 2 (Automatic - based on SIC, maxlag=20)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-13.27001	0.0000
Test critical values: 1% level	-3.969636	
5% level	-3.415478	
10% level	-3.129968	

*MacKinnon (1996) one-sided p-values.

Şekil 4.24. Logaritması ve Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerin Sabit Terimli ve Trendli ADF Birim Kök Test Sonucu

Null Hypothesis: DIFLOGDK has a unit root
 Exogenous: None
 Lag Length: 2 (Automatic - based on SIC, maxlag=20)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-12.86442	0.0000
Test critical values: 1% level	-2.567874	
5% level	-1.941222	
10% level	-1.616431	

*MacKinnon (1996) one-sided p-values.

Şekil 4.25. Logaritması ve Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Sabit Terimsiz ADF Birim Kök Testi Sonucu

Logaritması ve birinci dereceden farkı alınmış dolar kuru verilerinin hesaplanan ADF test istatistiği değeri kritik değerden küçük ise (negatif olarak) sıfır hipotezi ($H_0: \rho \geq 1$ ise seri durağan değildir.) reddedilir yani birim kök yoktur durağandır ve $H_1: \rho < 1$ ise seri durağandır bilgilerinden yola çıkılarak, Logaritması

ve birinci dereceden farkı alınmış dolar kuru verilerinin Şekil 4.23, Şekil 4.24 ve Şekil 4.25’ de ADF testinde durağan olduğu anlaşılabılır.

Şekil 4.22’de Otokorelasyona (ACF) bakıldığında zaman veri serisinin 2. Gecikmede güven sınırları içerisinde kaldığından dolayı MA (2) ve kısmi otokorelasyona (PACF) bakıldığında ise zaman veri serisinin 1 gecikmeden sonar sıfır eksenini kestiği için AR (1) modelinin uygun olacağı beklenmektedir. Yani modelin ARIMA (1, 1, 2) olacağı sonucuna varılmaktadır.

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	0.999908	0.000606	1649.799	0.0000
SAR(12)	-0.720682	0.569369	-1.265754	0.2060
MA(2)	0.085876	0.014446	5.944771	0.0000
SMA(12)	0.740045	0.562078	1.316622	0.1883
SIGMASQ	0.003746	3.80E-05	98.49171	0.0000
R-squared	0.998190	Mean dependent var	2.471786	
Adjusted R-squared	0.998181	S.D. dependent var	1.439450	
S.E. of regression	0.061399	Akaike info criterion	-2.725546	
Sum squared resid	2.993295	Schwarz criterion	-2.696238	
Log likelihood	1093.856	Hannan-Quinn criter.	-2.714286	
Durbin-Watson stat	1.739057			
Inverted AR Roots	1.00	.94-.25i	.94+.25i	.69+.69i
	.69-.69i	.25+.94i	.25-.94i	-.25-.94i
	-.25+.94i	-.69+.69i	-.69+.69i	-.94+.25i
	-.94-.25i			
Inverted MA Roots	.94-.25i	.94+.25i	.69-.69i	.69+.69i
	.25+.94i	.25-.94i	-.00+.29i	-.00-.29i
	-.25+.94i	-.25-.94i	-.69+.69i	-.69+.69i
	-.94-.25i	-.94+.25i		

Şekil 4.26. Dolar Kuru Veri Serisinin ARIMA Modelinin Parametre Tahmin Sonucu



Şekil 4.27. Dolar Kuru Zaman Veri Serisinin ARIMA Modelinin 15 Haftalık Tahmin Grafiği

Tablo 4.3. Dolar Kuru Zaman Veri Serisinin Gerçek ve 15 Haftalık Tahmin Değerleri

Tarih	Dolar Kuru(Gerçek)	Dolar Kuru(Tahmin)
07/01/2005	1.358960	
14/01/2005	1.370280	
21/01/2005	1.339233	
...	...	
21/02/2020	6.056080	
28/02/2020	6.133600	
06/03/2020	6.161400	
13/03/2020	6.136720	
20/03/2020	6.410660	
27/03/2020	6.484600	
03/04/2020	6.566040	
10/04/2020	6.738280	
17/04/2020	6.796500	
24/04/2020	6.937825	
		6.98711295
		7.01508662
		7.03915318
		7.06045891
		7.07981804
		7.09780809
		7.1148683
		7.13119844
		7.1470936
		7.1626689
		7.17802698
		7.19324044
		7.20836065
		7.22342394
		7.23845599


Tablo 4.4. Dolar Kurunun 15 Haftalık Tahmini İçin Kurulan Box-Jenkins ARIMA(1,1,2) Modelinin Hata Değerleri

R^2	MAE	MAD	MSE	MSLE	MAPE	RMSE
0.711945	0.674753	0.680119	0.589345	0.041121	30.576943	0.767688

4.2. Üstel Düzgünleştirme Tahmin Yöntemi

Durağanlığı test etmek için otokorelasyon ve kısmi otokorelasyon fonksiyonları kullanılmıştır. Otokorelasyon fonksiyonlarıyla beraber durağanlık testleri için kullanılan birim kök testlerine de başvurulmuştur. Kullandığımız zaman serisi için Phillips-Perron testi kullanılmıştır. Model kurulduktan sonra verisetimiz üstünde tahminlemeler gerçekleştirilmiştir.

Üstel düzgünleştirme tahmin yöntemlerini kullanmak ve sonuçları elde etmek için R Studio programından faydalanılmıştır.



Şekil 4.28. Dolar Kuru Verilerinin Haftalık Verilerin Yıllara Göre Grafiği

Dolar kurunun haftalık olarak elimizde olan verilerin her yılın aynı haftalarından oluşan grafikte, dolar kurunun herhangi bir mevsimsellik etkisi göstermediği anlaşılmıştır. Mevsimsellik etkisi olabilmesi için her yılın aynı zaman diliminde düşüş veya artış yaşanması beklenmiştir. Bazı yılların ard arda düşüş veya artış yaşaması durumunda tüm grafiğe bakılarak yorumlandığında tesadüfi olduğuna ulaşılmıştır.

Zaman serisi yöntemlerinde kullanılan üstel düzgünleştirme yöntemini daha etkili sonuçlar elde edebilmek için serinin durağanlığı kontrol edilmiştir. Bu işlem gerçekleştirilirken görsel olarak ACF ve PACF grafiklerinden, istatistiki olarak birim kök testlerinden yararlanılmıştır

Date: 05/17/20 Time: 16:11
Sample: 1 798
Included observations: 798

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
		1	0.993	0.993	789.16	0.000
		2	0.985	0.003	1567.7	0.000
		3	0.978	-0.007	2335.6	0.000
		4	0.971	-0.002	3093.0	0.000
		5	0.963	-0.001	3840.0	0.000
		6	0.956	0.005	4576.8	0.000
		7	0.950	0.051	5304.8	0.000
		8	0.943	0.000	6024.0	0.000
		9	0.937	-0.015	6734.3	0.000
		10	0.931	0.032	7436.4	0.000
		11	0.925	0.010	8130.8	0.000
		12	0.920	0.015	8817.7	0.000
		13	0.914	0.009	9497.5	0.000
		14	0.909	0.001	10170.	0.000
		15	0.904	-0.002	10836.	0.000
		16	0.898	-0.007	11494.	0.000
		17	0.893	-0.003	12146.	0.000
		18	0.887	-0.006	12790.	0.000
		19	0.882	0.004	13426.	0.000
		20	0.876	0.019	14057.	0.000
		21	0.871	0.007	14680.	0.000
		22	0.866	-0.004	15298.	0.000
		23	0.861	-0.004	15909.	0.000
		24	0.856	0.011	16513.	0.000
		25	0.851	0.003	17112.	0.000
		26	0.847	-0.002	17705.	0.000
		27	0.841	-0.022	18291.	0.000
		28	0.837	0.016	18871.	0.000
		29	0.832	0.022	19446.	0.000
		30	0.827	0.001	20015.	0.000
		31	0.823	-0.009	20578.	0.000
		32	0.818	-0.010	21136.	0.000
		33	0.813	-0.007	21688.	0.000
		34	0.808	-0.016	22234.	0.000
		35	0.803	0.018	22774.	0.000
		36	0.799	0.015	23309.	0.000
		37	0.794	-0.005	23838.	0.000
		38	0.790	-0.022	24362.	0.000
		39	0.784	-0.029	24879.	0.000
		40	0.779	-0.007	25391.	0.000
		41	0.774	-0.003	25895.	0.000
		42	0.768	-0.003	26394.	0.000

Şekil 4.29. Dolar Kuru Verilerinin ACF ve PACF Değerleri

Yukarıda ki sonuçlar eviews programından dolar kurlarının korelogram analizi yaparak elde edilmiştir. Burada ki autocorrelation acf ve kısmi correlation kısmi ise pacf sonuçlarını vermiştir. Şekilde görüleceği üzere serinin durağanlık (sabit) göstermediğini hatta zamanla azalan bir şekilde devam ettiği bilgisine acf tablosu üzerinden ulaşılmıştır.

Null Hypothesis: KUR has a unit root		
Exogenous: Constant		
Bandwidth: 10 (Newey-West automatic) using Bartlett kernel		
	Adj. t-Stat	Prob.*
Phillips-Perron test statistic	2.237739	1.0000
Test critical values: 1% level	-3.438329	
5% level	-2.864952	
10% level	-2.568641	
*Mackinnon (1996) one-sided p-values.		
Residual variance (no correction)		0.003680
HAC corrected variance (Bartlett kernel)		0.006017

Şekil 4.30. Dolar Kuru Verilerinin Sabit Terimli ve Trendsiz PP Testi Sonuçları

Null Hypothesis: KUR has a unit root		
Exogenous: Constant, Linear Trend		
Bandwidth: 10 (Newey-West automatic) using Bartlett kernel		
	Adj. t-Stat	Prob.*
Phillips-Perron test statistic	-0.134238	0.9943
Test critical values: 1% level	-3.969607	
5% level	-3.415464	
10% level	-3.129959	
*Mackinnon (1996) one-sided p-values.		
Residual variance (no correction)		0.003673
HAC corrected variance (Bartlett kernel)		0.006032

Şekil 4.31. Dolar Kuru Verilerinin Sabit Terimli ve Trendli PP Testi Sonuçları

Null Hypothesis: KUR has a unit root
 Exogenous: None
 Bandwidth: 10 (Newey-West automatic) using Bartlett kernel

	Adj. t-Stat	Prob.*
Phillips-Perron test statistic	3.292361	0.9998
Test critical values:		
1% level	-2.567867	
5% level	-1.941221	
10% level	-1.616432	
*Mackinnon (1996) one-sided p-values.		
Residual variance (no correction)		0.003686
HAC corrected variance (Bartlett kernel)		0.006115

Şekil 4.32. Dolar Kuru Verilerinin Sabit Terimsiz ve Trendsiz PP Testi Sonuçları

Zaman serinin durağanlık testleri genel olarak birim kök testleri ile sınanmıştır. Literatür araştırmasında belirttiğim Phillips-Perron testinden yararlanılmıştır. Yardımcı program olarak evIEWS kullanılmıştır. Bu testlerin sonucunda karşımıza t istatistiki değerleri ve p value değerleri dikkate alınacaktır. PP test istatistiği değeri kritik değerden küçük olduğu görülmüştür. P değeri de anlamlılık düzeyi 0,05'den küçük olması gerekmektedir. Bu iki değerde durağanlığı reddediği belirlenmiştir.

Null Hypothesis: D(KUR) has a unit root
 Exogenous: Constant
 Bandwidth: 10 (Newey-West automatic) using Bartlett kernel

	Adj. t-Stat	Prob.*
Phillips-Perron test statistic	-25.06544	0.0000
Test critical values:		
1% level	-3.438340	
5% level	-2.864956	
10% level	-2.568644	
*Mackinnon (1996) one-sided p-values.		
Residual variance (no correction)		0.003653
HAC corrected variance (Bartlett kernel)		0.004943

Şekil 4.33. Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Sabit Terimli ve Trendsiz PP Testi Sonuçları

Null Hypothesis: D(KUR) has a unit root
Exogenous: Constant, Linear Trend
Bandwidth: 9 (Newey-West automatic) using Bartlett kernel

	Adj. t-Stat	Prob.*
Phillips-Perron test statistic	-25.21805	0.0000
Test critical values:		
1% level	-3.969622	
5% level	-3.415471	
10% level	-3.129964	
*Mackinnon (1996) one-sided p-values.		
Residual variance (no correction)		0.003612
HAC corrected variance (Bartlett kernel)		0.004738

Şekil 4.34. Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Sabit Terimli ve Trendli PP Testi Sonuçları


Null Hypothesis: D(KUR) has a unit root
Exogenous: None
Bandwidth: 11 (Newey-West automatic) using Bartlett kernel

	Adj. t-Stat	Prob.*
Phillips-Perron test statistic	-24.96584	0.0000
Test critical values:		
1% level	-2.567870	
5% level	-1.941221	
10% level	-1.616432	
*Mackinnon (1996) one-sided p-values.		
Residual variance (no correction)		0.003688
HAC corrected variance (Bartlett kernel)		0.005158

Şekil 4.35. Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Sabit Terimsiz ve Trendsiz PP Testi Sonuçları


PP testini sabit terimli, sabit terimli ve trendli sabit terimsiz ve trendsiz şekilde test edildiğinde hepsinde durağanlığı reddetmiştir. Durağanlığın kabul edilebilmesi için t istatistik değeri ve p value değeri istenilen seviyede olması gerekmektedir. Bu aşamadan sonra serimizin durağanlaştırılması için birinci dereceden fark uygulanmıştır. Farkı alınan değerler üzerinde PP birim kök testi tekrardan uygulanmıştır. Uygulanan testler sonucunda serisini birinci dereceden farkı alınmasından sonra durağanlaştığı testler sonucunda elde edilen değerlerden anlaşılmıştır. Serinin durağanlaştığı belirlemek için, MacKinnon'un kritik

değerleriyle p değeri karşılaştırılıp anlamlılık düzeyini 0,05'den küçük olması beklenmiştir ve t istatistiki değerlerinin %1, %5, %10 seviyelerinde ki değerlerden küçük olması beklenmiştir. Her iki şartta sağlandığında serimiz durağanlaşmıştır. Serinin durağanlaştırılması, tahminleme yönteminde her değere ağırlık verilmesinde kolaylık sağlamıştır.



Şekil 4.36. Birinci Dereceden Farkı Alınmış Dolar Kuru Verilerinin Yıllara Göre Grafiği

Zaman serisinde olan verilerden daha iyi bir tahminleme yapabilmek için veriseti train ve test olmak üzere ikiye bölünmüştür. Zaman serisinde train değişkeni 2005-2018 verileri eklenmiştir, test değişkenine ise 2019-2020 verileri eklenmiştir. Bu modelde öncelikle train kısmında ki verileri üzerinden bir gerçekleştirme yapıp model eğitilip, tahmin yapılmıştır. Bu tahminleme yapılırken train veri setinin birinci dereceden farkı alınıp ağırlıklar belirlenmiştir. Bundan sonraki tüm modellerde gelecek için her zaman ilk 15 adımın tahminlemesi yapılmıştır.




Şekil 4.37. Birinci Dereceden Farkı Alınmış Train Veri Setinin Yıllara Göre Grafiği

Bu işlemler gerçekleştirildikten sonra test kısmında ise günümüzün tahminlemesi yapılmıştır. Tahminleme yapılırken train verisetinde durağanlaştırılarak verilen ağırlıklardan da yararlanılacaktır. Tahminleme yapılırken α katsayısının en iyi değeri vermesi için deneme yanılma yolu tercih edilmiştir. Bunun sonucunda α 'nın en iyi değerini bulmak için hata değerleriyle karşılaştırması yapılmıştır. İlk değeri vermek için 0,2 değeri kullanılmıştır.

Tablo 4.5. Basit Üstel Düzeltme Yöntemi Training ve Test Veri Setlerinin $\alpha=0,2$ için Hata Değerleri

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.005473169	0.05969562	0.02784303	0.1732542	1.180691	0.08782087
Test set	0.015348828	0.08418051	0.06920906	0.2630395	1.287011	0.21829517

Buradaki düzgünleştirme katsayısının RMSE için en düşük hata değeri bulunması amaçlanmıştır. Bunun sonucunda aşağıdaki grafiğin fonksiyonu yazılarak yardım alınmıştır.



Şekil 4.38. Basit Üstel Düzeltme Yöntemi Training ve Test Veri Setlerinin α Değeri ve RMSE Grafiği

$\alpha=0,46$ değeriyle RMSE'nin en düşük hata değeri 0,569 olmuştur. Bulunan optimal α değeri için yapılan tahminlemeler için hata değerleri şöyle olmuştur.

Tablo 4.6. Basit Üstel Düzeltme Yöntemi Training ve Test Veri Setlerinin $\alpha=0,46$ için Hata Değerleri

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	5.238232e-05	0.06407298	0.02971105	26.87572	319.8875	0.7783445
Test set	-6.928683e-04	0.05693096	0.04750429	98.78171	106.3469	1.2444765

RMSE hata değerleri üzerinden yapılan iyileştirme sonucunda hata değeri 0.0841 değerinden 0.05693 değerine indirgenmiştir. Böylelikle hata değerinde %32 iyileştirme yapılmıştır.

Bu iyileştirmelerden sonra y basit üstel düzgünleştirme tahmin yöntemiyle elde edilen tek bir sonuç vardır. Bunun sebebi bu modelde ağırlıkların sabit kalması ve değişmemesinden kaynaklanmıştır.

Tablo 4.7. Basit Üstel Düzeltme Yöntemin $\alpha=0,46$ Değeriyle Yapılan Tahmin Değerleri

Point Forecast	Low 80	High 80	Low 95	High 95
6.799958	6.692583	6.907332	6.635742	6.964173


Burada gerçekleşmiş olan en yüksek ve en düşük değerlerin %80 ve %95 güvenilirlilik oranları olan tahminin sonuçları gösterilmiştir.

Çalıştığımız zaman serisi için en uygun model Holt'un trend yöntemidir. Bu model de trend faktörü dikkate alınmıştır. Kurulan model de parametre olarak karşımıza beta katsayısı çıkmıştır. Beta katsayısının en optimal değeri bulunması çalışmıştır. Daha öncesinde ikiye bölünen veri setlerimizden train eğitilmiş ve durağanlaştırılmış verilerden yararlanılarak bir tahminleme yapılmıştır. Bunlardan elde edilen hata değerleri aşağıda gösterilmiştir.

Tablo 4.8. Holt Trend Metoduyla Training ve Test Veri Setlerinin Otomatik Oluşturulan Beta Değerinin 15 Haftalık Tahmin İçin Hata Değerleri

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.00260640	0.05941022	0.02780111	0.07006808	1.179903	0.08768865
Test set	-0.08728144	0.11786544	0.09658756	-1.64890196	1.820303	0.30465086

Öncelik olarak çalışmamızda RMSE'nin düşürülmesi amaçlanmıştır. RMSE değerinin en düşük hata değerini vermesi için optimal beta katsayısı bulunmaya çalışılmıştır.



Şekil 4.39. Holt Trend Metoduyla Training ve Test Veri Setlerinin beta Değeri ve RMSE Grafiği

Yukarıda ki grafiğin uygulanması sonrasında elde edilen en optimal beta değerimiz 0,375 bulunmuştur. Bunun sonucunda durağanlaştırılmış veriler üzerinden tahminleme modelinin bu değer ile kullanıldığında aşağıdaki hata değerleri elde edilmiştir.

Tablo 4.9. Holt Trend Metoduyla Training ve Test Veri Setlerinin Otomatik Oluşturulan $\beta=0,375$ Değerinin 15 Haftalık Tahmin İçin Hata Değerleri


	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	4.47126e-05	0.06201878	0.02995976	0.01150297	1.271790	0.09449733
Test set	-5.33805e-03	0.07703135	0.06543835	-0.12121836	1.223408	0.20640183

İyileştirilmiş olan beta katsayısı sonucunda hata değerinin 0,1178'den 0,0770'a indirgenmiştir. Bu değerler sonucunda hata değerinde %34'lük bir iyileştirme yapılmıştır. Modelin iyileştirilmesinden sonra bulunan beta değeriyle gelecek için yapılan ilk 15 değer tahminlemesi şöyle olmuştur.

Tablo 4.10. Holt Trend Metoduyla Training ve Test Veri Setlerinin Otomatik Oluşturulan $\beta=0,375$ Değerinin 15 Haftalık Tahmin

Point Forecast	Low 80	High 80	Low 95	High 95
6.957197	6.879017	7.035377	6.737631	7.076763
6.976581	6.765582	7.087580	6.806823	7.146339
6.995965	6.859481	7.132450	6.787230	7.204700
7.015350	6.857126	7.173573	6.773368	7.257331
7.034734	6.857135	7.212333	6.763120	7.306348
7.054118	6.858800	7.249436	6.755406	7.352830
7.073502	6.761704	7.285300	6.749586	7.397419
7.092886	6.865576	7.320197	6.745245	7.440528
7.112271	6.870227	7.354314	6.742097	7.482444
7.131655	6.875522	7.387788	6.739933	7.523376
7.151039	6.881358	7.420720	6.738597	7.563481
7.170423	6.887656	7.453190	6.737968	7.602878
7.189807	6.894354	7.485261	6.737950	7.641665
7.209192	6.901400	7.516983	6.738465	7.679919
7.228576	6.908753	7.548398	6.739449	7.717702

Yapılan tahminlerin en yüksek ve en düşük değerlerinin %80, %95 güven aralıklarında tahminide görüldüğü gibi olmuştur.




Şekil 4.40. Holt Trend Metoduyla Training ve Test Veri Setlerinin Otomatik Oluşturulan $\beta=0,375$ Değerinin 15 Haftalık Tahmin Grafiği

Tahminlemelerde en iyi yöntemi ve sonuçları elde etmeye çalışırken literatür araştırmasında bahsettiğim trendin zaman azacalağıu veya artacağı yönünde bir tahmin bulunup, bunun içinde bir pi katsayısı tanımlayıp tahmin yapılabildiğinden bahsedilmiştir. Bununla ilgili bir örnekleme gerçekleştirilmiştir ve elde edilen sonuçlar aşağıda paylaşılmıştır.

Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
	7.024806	6.945019	7.104593	6.902782	7.146830
	7.112270	6.986987	7.237553	6.920666	7.303874
	7.190987	7.012616	7.369358	6.918192	7.463782
	7.261833	7.025982	7.497684	6.901130	7.622536
	7.325594	7.029565	7.621624	6.872856	7.778333
	7.382979	7.025132	7.740827	6.835699	7.930260
	7.434626	7.014047	7.855205	6.791406	8.077846
	7.481108	6.997406	7.964810	6.741350	8.220866
	7.522942	6.976113	8.069771	6.686639	8.359244
	7.560592	6.950921	8.170263	6.628181	8.493003
	7.594477	6.922468	8.266486	6.566728	8.622226
	7.624974	6.891295	8.358653	6.502909	8.747039
	7.652421	6.857863	8.446979	6.437250	8.867593
	7.677124	6.822568	8.531679	6.370193	8.984054
	7.699356	6.785748	8.612964	6.302113	9.096598

Şekil 4.41. Holt Yavaşlayan(Damped) Trend Metoduyla Training ve Test Veri Setlerinin $\pi=0,9$ Değeri ile 15 Haftalık Tahmin



Şekil 4.42. Holt Yavaşlayan(Damped) Trend Metoduyla Training ve Test Veri Setlerinin $\pi=0,9$ Değeri ile 15 Haftalık Tahmin Grafiği

4.3. Lstm


Araştırmanın bu kısmında, yinelenen sinir ağları çeşitlerinden birisi olan LSTM mimarisi kullanılmıştır. LSTM mimarisi uzun zaman önceki verileri tahmin etmede gerçekten başarılı sonuçlar üretmektedir. Veri seti sayısının yüksek olduğu durumlarda daha iyi sonuçlar üretse de az olduğu durumlarda da başarılı sonuçlar ürettiğini söylenebilir (Gers, 2001). Bu projede 2005 - 2020 tarihleri arasındaki dolar kuru verileri üzerinde çalışılmıştır. Proje kapsamında programlama dili olarak Python, kütüphane olarak ise keras, tensorflow, scikit – learn ve plotly kütüphaneleri kullanılmıştır. Model eğitim seti üzerinde 15, 30 ve 45 epoch ile eğitilmiştir. Modelin kayıp fonksiyonu kök ortalama hata kareler RMSE ile bulunmuştur.

Cumartesi ve pazar günleri piyasanın kapalı olması sebebiyle interpolate fonksiyonu kullanılarak lineer olarak bir doldurma işlemi yapılmıştır. Veri eğitim ve test olarak iki kısma bölünmüştür. %60 train ve %40 olarak bir bölme işlemi yapılmıştır. Veri setleri oluşturulup daha sonra lstm modeli oluşturulmuş ve daha sonra sonuçları ölçüp incelemeler yapılmıştır.

Tablo 4.11. Dolar Kuru Verilerinin LSTM ile 15 Epoch Sonuçları

Epoch	Dolar Kuru Tahmin	Train RMSE	Test RMSE
15	6.997593	0.07	0.02
	7.093621		
	7.144956		
	7.189053		
	7.229442		
	7.267489		
	7.303894		
	7.339058		
	7.373257		
	7.406677		
	7.439452		
	7.471681		
	7.503441		
	7.534796		
	7.565797		


Training data score: 0.07 RMSE
Test data score: 0.02 RMSE



Şekil 4.43. Dolar Kuru Verilerinin LSTM ile 15 Epoch'un Sonuçlarının Grafiği

Tablo 4.12. Dolar Kuru Verilerinin LSTM ile 30 Epoch Sonuçları

Epoch	Dolar Kuru Tahmin	Train RMSE	Test RMSE
30	7.019770	0.13	0.05
	7.118773		
	7.171688		
	7.217134		
	7.258754		
	7.297955		
	7.335459		
	7.371686		
	7.406914		
	7.441335		
	7.475088		
	7.508273		
	7.540976		
	7.573257		
	7.605168		



Şekil 4.44. Dolar Kuru Verilerinin LSTM ile 30 Epoch Sonuçlarının Grafiği


Tablo 4.13. Dolar Kuru Verilerinin LSTM ile 45 Epoch Sonuçları

Epoch	Dolar Kuru Tahmin	Train RMSE	Test RMSE
45	6.902123	0.18	0.07
	6.995135		
	7.044821		
	7.087477		
	7.126530		
	7.163304		
	7.198472		
	7.232436		
	7.265454		
	7.297705		
	7.329324		
	7.360401		
	7.391018		
	7.421234		
	7.451097		

Tahmin işlemleri yapılırken 15 ve 30 epoch değerleri için oluşan tahmini değerler ve train ve test RMSE değerleri tablo olarak ve oluşan grafik çözümü de verilmiştir. 40 epoch değeri için ise sadece tablo olarak verilmiştir. Epoch değerleri artarken RMSE değerlerinin arttığı gözlemlenmiştir.

BÖLÜM 5. SONUÇ

Araştırmada kullanılan ARIMA, HOLT ve LSTM yöntemleriyle beraber dolar kuru tahminleri gerçekleştirilmiştir. Belirtilen bölümlerde sonuçlar paylaşılmıştır.



Şekil 5.45. TCMB 2005-2020 Yılları Arasındaki Dolar Kuru Verileri Üzerinden Yapılan Tahmin Sonuçlarının Karşılaştırılması

Dolar kuru tahmininde kullanılan yöntemler yukarıda belirtildiği gibidir. Bu belirtilen tahmin yöntemleri üzerinden yapılan tahminlemeleri birbirleriyle karşılaştırmak için hata değerlerinden faydalanılmıştır. Hata değeri ortak olarak RMSE'ye göre yapılmıştır. RMSE değerleri Box-Jenkins ARIMA modeli için Tablo 4.4'de 0,76 , Üstel Düzeltme Yönteminin HOLT modeli için Tablo 4.9'da 0,07 ve Makine Öğrenmesinde LSTM için Tablo 4.11'de 0,02 olduğu görülmüştür. Elde edilmiş olan bu hata değerlerine bakıldığında LSTM modelinin diğer modellere göre daha az hata oranına sahip olduğu görülmüştür. İleriye yönelik yapılacak olan dolar kuru tahmininde Makine Öğrenmesinden LSTM modeli en başarılı sonuca ulaşmıştır.

Gelecek için yapılacak olan USD tahmini çalışmalarında LSTM yöntemiyle beraber HOLT yöntemini melez şekilde kullanmak daha faydalı sonuçlar ortaya çıkarabilecektir.

BÖLÜM 6. Kaynakça

- Akdağ, M. (2015). *Box-Jenkins ve Yapay Sinir Ağı Modelleri İle Enflasyon Tahmini*. Atatürk Üniversitesi Fen Bilimleri Enstitüsü Endüstri Mühendisliği Anabilim Dalı Yüksek Lisans Tezi.
- Akgül, I. (2003). *Zaman Serilerinin Analizi Ve ARIMA Modelleri*. İstanbul: Der Yayınevi.
- Akıl, A. (2019). *Euro/Dolar Paritesindeki Değişimin Zaman Serisi Analizi İle İncelenmesi*. Süleman Demirel Üniversitesi Fen Bilimleri Enstitüsü Matematik Anabilim Dalı Yüksek Lisans Tezi.
- Akıncı, M. (2008). *Zaman Serilerinde Durağanlık Analizi ve İhracatın GSMH İçindeki Payı Üzerine Bir Uygulama*. Kafkas Üniversitesi Sosyal Bilimler Enstitüsü İşletme Anabilim Dalı Yüksek Lisans Tezi.
- Akşit, S. (2019). *Küresel İklim Değişikliği Boyutunun Box-Jenkins Metodu İle İncelenmesi: Ankara İli Örneği*. Gazi Üniversitesi Fen Bilimleri Enstitüsü Çevre Anabilim Dalı Yüksek Lisans Tezi.
- Alam. (2018). *Alam, S. Recurrent neural networks in electricity load forecasting*. .
- ALAN, M. A. (2014). *Karar Ağaçlarıyla Öğrenci Verilerinin Sınıflandırılması*.
- Allen. (1964). *R.G.D, Statics for Economists*. United Kingdom: Mc- Millan.
- Almahmud, B. (2019). *Yapay Sinir Ağı ve Box-Jenkins Modeli İle Yazıcı Sarf Malzemeler Verilerinin Tahmini Irak Örneği*. Süleyman Demirel Üniversitesi Fen Bilimleri Enstitüsü Bilgisayar Mühendisliği Anabilim Dalı Yüksek Lisans Tezi.
- Alpaydın ve Bach. (2014). *Introduction to Machine Learning 3rd Edition*. MIT Press.
- Aydemir, E. (2013). *Kusurlu Ürünleri İçeren Ekonomik Üretim Miktarı Modelinin Gri Sistem Teorisi Yaklaşımıyla Geliştirilmesi: Endüstriyel Bir Araştırma*. Süleyman Demirel Üniversitesi Fen Bilimleri Enstitüsü Makine Mühendisliği Anabilim Dalı Doktora Tezi.
- Bell J. (2014). *Machine Learning : Hands-On for Developers and Technical Professionals*. Somerset . United States: John Wiley & Sons, Incorporated.
- Bengio, Simard ve Franscon. (2015). *Bengio, Y., Simard, P., & Franscon P.. Learning Long-Term Dependencies with Gradient Descent is Difficult. IEEE Trans. Neural Networks*.

- Bergmeir ve Benitez. (2012). *On the use of cross-validation for time series predictor evaluation*. Information Sciences.
- Bıçen, C. (2006). *Box-Jenkins Zaman Serisi Analiz Yöntemi İle İleri Beslemeli Yapay Sinir Ağları Tahminlerinin Karşılaştırılması*. Hacettepe Üniversitesi Sağlık Bilimleri Enstitüsü Biyoistatistik Programı Yüksek Lisans Tezi.
- Bozdağ, H. (2011). *Box-Jenkins Ve Yapay Sinir Ağı Yöntemleri İle Havalimanı Yolcu Talebi Öngürülenmesi : Antalya Havalimanı Örneği* . Süleyman Demirel Üniversitesi Sosyal Bilimler Enstitüsü Ekonometri Anabilim Dalı Yüksek Lisans Tezi.
- Breiman. (2001). *Breiman L. Random Forests. J Mach Learn*.
- Brownlee. (2017). *CNN Long Short-Term Memory Networks*.
- Brownlee J. (2016). *Machine learning mastery* .
- Can, M. (2009). *İşletmelerde Zaman Serileri Analizi İle Tahmin*. İstanbul Üniversitesi Sosyal Bilimler Enstitüsü İşletme Anabilim Dalı Doktora Tezi.
- Carvalho ve Freitas. (2004). . *A hybrid decision tree/genetic algorithm method for Data mining*.
- Chapelle ve Schölkopf. (2006). *Semi-Supervised Learning Edited*. London: The MIT Press.
- Cho ve diğerleri. (2014). *Cho, K., Dzmitry, B., Gulcehre, C., Bougares, F., Schwenk, H., & Bengio, Y. Encoder Decoder, Learning Phrase Representations using RNN Encoder Decoder for Statistical Machine Translation. Proceedings of the 2014 Conference on Empirical Methods in*. Doha, Qatar: Association for Computational Linguistics.
- Chung ve diğerleri. (2015). *J. Chung, C. Gulcehre, K. Cho, and Y. Bengio, Gated feedback recurrent neural networks*. Proceedings of the 32nd International Conference on Machine Learning .
- Çevik, O. (1999). *Zaman Serileri Analizinde Box-Jenkins Yöntemi Ve Turizm Verileri Üzerine Bir Uygulama*. Kırıkkale Üniversitesi Sosyal Bilimler Enstitüsü İşletme Anabilim Dalı Doktora Tezi.
- Çiğdem, Ş. (2009). *Zaman Serileri Analizinde Mevsimsel Düzeltme Yöntemleri ve Aylık Sanayi Üretim İndeksine Uygulanması*. Gazi Üniversitesi Fen Bilimleri Enstitüsü İstatistik Anabilim Dalı Yüksek Lisans Tezi.

- Çuhadar, M. (2006). *Turizm Sektöründe Talep Tahmini İçin Yapay Sinir Ağlarının Kullanımı ve Diğer Yöntemlerle Karşılaştırılmalı Analizi (Antalya İlinin Dış Turizm Talebinde Uygulama)*. Süleyman Demirel Üniversitesi Sosyal Bilimler Enstitüsü İşletme Anabilim Dalı Doktora Tezi.
- D. Silver. (2016). *Mastering the game of Go with deep neural networks and tree search*.
- Demirbaş, F. P. (2011). *Kombi Üretiminde Talep Tahmin Yöntemlerinin Uygulanması*. Kocaeli Üniversitesi Fen Bilimleri Enstitüsü Endüstri Mühendisliği Anabilim Dalı Yüksek Lisans Tezi.
- Duru, Ö. (2007). *Zaman Serileri Analizinde ARIMA Modelleri Ve Bir Uygulama*. İstanbul Üniversitesi Sosyal Bilimler Enstitüsü Ekonometri Anabilim Dalı Yüksek Lisans Tezi.
- Ersen, N. (2016). *Türkiye'nin Ağaç ve Orman Ürünleri İhracat ve İthalat Değerlerinin Box-Jenkins ve Yapay Sinir Ağları Yöntemleri İle Tahmin Edilmesi ve Karşılaştırılması*. Karadeniz Teknik Üniversitesi Fen Bilimleri Enstitüsü Orman Endüstri Mühendisliği Anabilim Dalı Doktora Tezi.
- Ertek, T. (2000). *Ekonometriye Giriş*. İstanbul: Beta Basım Yayın.
- Fausett. (1994). *Fundamentals of Neural Networks: Architecture, Algoritma and Applications*. New Jersey: Printice Hall.
- Gers, F. (2001). *Felix Gers, Long Short-Term Memory in Recurrent Neural Networks*. Berlin.
- Göktaş, Ö. (2005). *Teorik ve Uygulamalı Zaman Serileri Analizi*. İstanbul: Beşir Kitabevi.
- Grim ve Gradvohl. (2018). *High-Performance Ensembles of Online Sequential Extreme Learning Machine for Regression and Time Series Forecasting. 2018 30th International Symposium on Computer Architecture and High Performance Computing . IEEE*.
- Güneş, M. (2010). *Zaman Serilerinde Müdahale Analiz Teknikleri Üzeride Bir Çalışma*. Namık Kemal Üniversitesi Fen Bilimleri Enstitüsü Matematik Anabilim Dalı Yüksek Lisans Tezi.
- Hague. (2011). *Hague, Paul. A Practical Guide To Market Research*.

- Horosan, E. B. (2011). *Box-Jenkins Modelleri İle Bağımsız Denetim Uygulaması*. Marmara Üniversitesi Sosyal Bilimler Enstitüsü İşletme Anabilim Dalı Muhasebe Denetimi Bilim Dalı Yüksek Lisans Tezi.
- Jahnke. (2015). *Machine Learning Approaches for Failure Type Detection and Predictive Maintenance*.
- Jiang ve Zhou. (2004). *Editing Training Data for KNN Classifiers with Neural Network Ensemble*. In *International Symposium on Neural Networks* . Berlin.
- Karasar. (2005). *Bilimsel Araştırma Yöntemi*. Nobel Yayın Dağıtım.
- Kass. (1980). *An exploratory technique for investigating large quantities of categorical data.* *Journal of the Royal Statistical Society: Series C (Applied Statistics)*.
- Kaya, E. (2019). *Zaman Serileri Analizinde Box-Jenkins Yöntemi İle Savunma Sanayi Verilerini Üzerinde Bir Uygulama*. Karamanoğlu Mehmetbey Üniversitesi Sosyal Bilimler Enstitüsü İşletme Anabilim Dalı Yüksek Lisans Tezi .
- Kılınç ve diğerleri. (2016). *Kılınç Deniz, Borandağ Emin, Yücalar Fatih, Tunalı Volkan, Şimşek Macit, Özçift Akın, “KNN Algoritması ve R Dili ile Metin Madenciliği Kullanılarak Bilimsel Makale Tasnifi”*.
- Kırçıl, M. (2013). *Box-Jenkins Yöntemi İle Konut Doğalgaz Talebinin Tahminlenmesi : İzmir İli Örneği*. Süleyman Demirel Üniversitesi Sosyal Bilimler Enstitüsü Ekonometri Anabilim Dalı Yüksek Lisans Tezi.
- Kızılkaya ve Oğuzlar. (2018). *Yusuf Murat Kızılkaya ve Ayşe Oğuzlar, BAZI DENETİMLİ ÖĞRENME ALGORİTMALARININ R*.
- Klaus. (2016). *Greff, Klaus et al. “LSTM: A Search Space Odyssey”*. In: *IEEE Transactions on Neural Networks and Learning Systems*.
- Kolassa ve Siemsen. (2016). *Demand forecasting for managers*. Business. Expert Press.
- Liliana ve Napitupulu. (2012). *Artificial Neural Network Application in Gross Domestic Product Forecasting an Indonesia Case*. *Journal of Theoretical and Applied Information Technology*.
- Maindonald ve Braun. (2006). *Data analysis and graphics using R: an example-based approach* . Cambridge University Press.

- Manning ve Schutze. (1999). *Manning C.D. and Schutze H., 1999 Foundations of Statistical Natural Language Processing*. Cambridge MIT Press.
- Mehrotra ve diğerleri. (2000). *'Elements of artificial neural networks'*. The MIT Press.
- Mehryar Mohri. (2012). *Mehryar Mohri, A. R. Foundations of Machine Learning*. United States: Cambridge MIT Press.
- Mitchell. (2006). *Short- and long-term implicit memory in aging and Alzheimer's disease*.
- Mohri ve diğerleri. (2012). *Mohri, Rastomizahed & Talwalkar*.
- Olcan, C. (2015). *Güneş Radyasyon Tahmini İçin Bulanık Zaman Serisi Yöntemleri ve Fotovoltaik Sulama Sistemi Optimizasyonunda Uygulanması*. İstanbul Teknik Üniversitesi Fen Bilimleri Enstitüsü Endüstri Mühendisliği Anabilim Dalı Doktora tezi.
- Orhunbilge, N. (1999). *Zaman Serileri Analizi Tahmin ve Fiyat İndeksleri*. İstanbul: Tunç Matbaacılık.
- Öztemel. (2003). *Applying Industry 4.0 to the Jurong Island Eco-industrial Park, EnergyProcedia*. İstanbul: Papatya Yayıncılık.
- Pilavcılar, İ. (2007). *Metin madenciliği ile metin sınıflandırma*. Yıldız Teknik Üniversitesi Fen Bilimleri Enstitüsü Yüksek Lisans Tezi.
- Polat, Ö. (2009). *Türkiye'nin Dış Ticaret Verilerinin Öngörüsünde Yapay Sinir Ağları Ve Box-Jenkins Modellerinin Karşılaştırmalı Analizi*. Atatürk Üniversitesi Sosyal Bilimler Enstitüsü İktisat Anabilim Dalı Doktora Tezi.
- Quinlan. (1986). *Quinlan JR. Induction of decision trees. International J Mach Learn*.
- Rahman ve Davis. (2013). *Machine Learning-Based Missing Value Imputation Method for Clinical Datasets. IAENG Transactions on Engineering Technologies: Special Volume of the World Congress on Engineering 2012. G.-C. Yang, S.-I. Ao and L. Gelman. Dordrecht, Springer Netherlands*.
- Recurrent Neural Networks - 02 Long Short-Term Memory*. (2017). 2020 tarihinde neurocat: <https://neurocats.github.io/2017/09/15/lstm/> adresinden alındı
- Recurrent Neural Networks And Lstm*. (2018). 2020 tarihinde builtin: <https://builtin.com/data-science/recurrent-neural-networks-and-lstm> adresinden alındı

- Rish I. (2001). *An empirical study of the naive Bayes classifier*. .
- S. Hochreiter ve J. Schmidhuber. (1997). *Long short- term memory, Neural Computation*.
- Sağıroğlu, Beşdok ve Erler. (2003). *Mühendislikte Yapay Zeka Uygulamaları– I:Yapay Sinir Ağları*. Ufuk Kitap Kırtasiye–Yayınclık Tic. Ltd. Şti.
- Shearer. (2000). *The CRISP-DM model: the new blueprint for data mining*. Journal of data warehousing.
- Simon. (2013). *Too Big to Ignore: The Business Case for Big Data*.
- Simple RNN vs GRU vs LSTM. (2018). 2020 tarihinde MC.AI: <https://mc.ai/simple-rnn-vs-gru-vs-lstm-difference-lies-in-more-flexible-control/> adresinden alındı
- Sinir Ağları. (2017). 2020 tarihinde ardamavi: <https://www.ardamavi.com/2017/07/sinir-aglari.html> adresinden alındı
- Sutton ve diğerleri. (1998). *Sutton, R. S. & A. G. Barto Introduction to reinforcement learning*. MIT press Cambridge.
- Şener, S. (2019). *Makine Öğrenmesi Yardimiyla Zincir Restoran Gıda Satışlarının Tahmin Edilmesi ve Hava Durumunun Etkisinin İncelenmesi*. İstanbul Teknik Üniversitesi Fen Bilimleri Enstitüsü Yüksek Lisans Tezi.
- Şenyüz, M. (2019). *Türkiye'deki Organik Tarım Ürünlerinin Zaman Serileri İle Analizi*. İstanbul Üniversitesi Sosyal Bilimler Enstitüsü İşletme Anabilim Dalı Yüksek Lisas Tezi.
- TCMB. (2020). *Türkiye Cumhuriyeti Merkez Bankası*. 01 01, 2020 tarihinde <https://www.tcmb.gov.tr> adresinden alındı
- towardsdatascience.com. (2019). *Machine learning and its scope*. 2020 tarihinde Towards Data Science: <https://towardsdatascience.com/machine-learning-and-its-scope-for-core-engineers-with-a-cup-of-coffee-10e7482856f9> adresinden alındı
- Turing. (1950). *Computing machinery and intelligence*.
- Türkoğlu. (2007). *Karar Ağaçları Ve Fraktal Analiz Kullanarak Histopatolojik İmgelerin Sınıflandırılması*. Ankara: Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi.
- Tüzen, M. F. (2012). *Türkiye Turizm Gelirinin Öngörüsünde Zaman Serilerinin Bileşenlerine Ayırıştırılarak Yapay Sinir Ağları Ve Box-Jenkins Yöntemleri İle*

- Karşılaştırmalı Analizi*. Kafkas Üniversitesi Sosyal Bilimler Enstitüsü İşletme Anabilim Dalı Yüksek Lisans Tezi.
- Üçler, G. (2011). *Kamu Harcama Çeşitleri ve Ekonomik Büyüme İlişkisi: Türkiye Ekonomisi İçin Ekonometrik Bir Analiz (1970-2009)*. Selçuk Üniversitesi Sosyal Bilimler Enstitüsü Doktora Tezi.
- Üreten. (2005). *Sevinç Üreten, Üretim/İşlemler Yönetimi, Stratejik Kararlar ve Karar Modelleri*. Ankara: Gazi Kitabevi.
- Yoloğlu, Z. (2020). *Döviz Kuru ve Faiz Oranı İle Hisse Senedi Arasındaki Volatilite Yayılımı: Çok Değişkenli Garch Modelleri İle Bir Uygulama*. Çağ Üniversitesi Sosyal Bilimler Enstitüsü İşletme Yönetimi Ana Bilim Dalı Yüksek Lisans Tezi.
- Zhang ve diğerleri. (1998). *Forecasting with artificial neural networks: the state of the art*. Inter: Journal of Forecasting.

EKLER

ÖZGEÇMİŞ

Kutay Uzunçelebi, 14.03.1997'de Karabük'te doğdu. İlk, orta, lise eğitimini Karabük'te tamamladı. 2015 yılında 75.Yıl Karabük Anadolu Lisesi'nden mezun oldu. 2016 yılında Sakarya Üniversitesi Bilişim Sistemleri Mühendisliği Bölümü'nü kazandı ve hala okumakta. 2019 yılının yaz aylarında yazılım stajını İSKİ'de ve işletme stajını ise Karabük Demir Çelik Sanayi ve Ticaret A.Ş.'de yapmıştır.

Sena Efe, 19.07.1998'de Kocaeli'de doğdu. İlk, orta, ve lise eğitimini Kocaeli'de tamamladı. 2016 yılında Kocaeli Final Özel Temel Lisesi'nden mezun oldu. 2016 yılında Sakarya Üniversitesi Bilişim Sistemleri Mühendisliği Bölümü'nü kazandı ve hala okumakta. 2019 yılının yaz aylarında yazılım ve işletme stajlarını Prometeon Turkey Endüstriyel ve Ticari Lastikler A.Ş.'de yapmıştır.

Furkan Aşan, 13.07.1997 de İzmir KONAK'ta doğdu. İlk, orta ve lise eğitimini Ankara'da tamamladı. 2014-2015 eğitim öğretim döneminde İncirli Endüstri Meslek Lisesi Bilişim Bölümü'nden mezun oldu. 2016 yılında Sakarya Üniversitesi Bilişim Sistemleri Mühendisliği Bölümü'nü kazandı ve hala okumakta. 2020 yılında mezun olacaktır. 2019 yılında işletme stajını DÖKTAŞ A.Ş'de yapmıştır.

ISE 402 BİTİRME ÇALIŞMASI DEĞERLENDİRME VE SÖZLÜ SINAV TUTANAĞI

KONU :

ÖĞRENCİLER (Öğrenci No/AD/SOYAD):

Değerlendirme Konusu	İstenenler	Not Aralığı	Not
Yazılı Çalışma			
Çalışma klavuza uygun olarak hazırlanmış mı?	x	0-5	
Teknik Yönden			
Problemin tanımı yapılmış mı?	x	0-5	
Geliştirilecek yazılımın/donanımın mimarisini içeren blok şeması (yazılımlar için veri akış şeması (dfd) da olabilir) çizilerek açıklanmış mı?			
Blok şemadaki birimler arasındaki bilgi akışına ait model/gösterim var mı?			
Yazılımın gereksinim listesi oluşturulmuş mu?			
Kullanılan/kullanılması düşünülen araçlar/teknolojiler anlatılmış mı?			
Donanımların programlanması/konfigürasyonu için yazılım gereksinimleri belirtilmiş mi?			
UML ile modelleme yapılmış mı?			
Veritabanları kullanılmış ise kavramsal model çıkarılmış mı? (Varlık ilişki modeli, noSQL kavramsal modelleri v.b.)			
Projeye yönelik iş-zaman çizelgesi çıkarılarak maliyet analizi yapılmış mı?			
Donanım bileşenlerinin maliyet analizi (prototip-adetli seri üretim vb.) çıkarılmış mı?			
Donanım için gerekli enerji analizi (minimum-uyku-aktif-maksimum) yapılmış mı?			
Grup çalışmalarında grup üyelerinin görev tanımları verilmiş mi (iş-zaman çizelgesinde belirtilebilir)?			
Sürüm denetim sistemi (Version Control System; Git, Subversion v.s.) kullanılmış mı?			
Sistemin genel testi için uygulanan metotlar ve iyileştirme süreçlerinin dökümü verilmiş mi?			
Yazılımın sızma testi yapılmış mı?			
Performans testi yapılmış mı?			
Tasarımın uygulamasında ortaya çıkan uyumsuzluklar ve aksaklıklar belirtilerek çözüm yöntemleri tartışılmış mı?			
Yapılan işlerin zorluk derecesi?	x	0-25	
Sözlü Sınav			
Yapılan sunum başarılı mı?	x	0-5	
Soruları yanıtlama yetkinliği?	x	0-20	
Devam Durumu			
Öğrenci dönem içerisindeki raporlarını düzenli olarak hazırladı mı?	x	0-5	
Diğer Maddeler			
Toplam			

DANIŞMAN (JÜRİ ADINA):

DANIŞMAN İMZASI: